PolyRL: aprendizaje por refuerzo en mercados horarios de predicción de Bitcoin

Informe final del proyecto de Aprendizaje por Refuerzo

Fecha: 9 de noviembre de 2026

Código y materiales reproducibles: https://github.com/donmatthiuz/RL/tree/proyecto

Resumen

Se estudió si agentes de aprendizaje por refuerzo pueden decidir cuándo comprar YES, comprar NO, vender o esperar en mercados horarios *Bitcoin Up or Down* de Polymarket. El estudio usa precios históricos de Polymarket y velas de Binance, un simulador con costos de transacción y saldo ficticio, y una evaluación temporal fuera de muestra. Se capturaron 12 471 mercados; el conjunto final comprende 8 682 mercados de entrenamiento, 1 861 de validación y 1 751 de test. Se entrenaron PPO, DQN, CQL y BC con cinco semillas por algoritmo y se compararon con seis reglas sencillas. El protocolo fijó de antemano la comparación principal contra `NoTrade`, una mejora relevante de 1 % del monto por mercado y un intervalo ajustado por cuatro comparaciones. En test ningún agente superó a `NoTrade`: PPO y DQN quedaron equivalentes en el modo normal, CQL fue inferior y BC operó tan poco que su intervalo no es confiable. El principal aprendizaje es metodológico: al corregir el tiempo de disponibilidad del precio y cobrar spread y comisión, desaparece una ventaja que parecía rentable.

Palabras clave: aprendizaje por refuerzo, mercados de predicción, backtesting, sesgo temporal, PPO, DQN, aprendizaje fuera de línea.

1. Descripción del problema

Polymarket ofrece mercados binarios en los que un token YES y otro NO representan los dos posibles resultados de una pregunta. En la familia estudiada, la pregunta es si Bitcoin sube o baja durante una vela de una hora. Una acción del lado ganador paga una unidad al resolverse y la perdedora paga cero. Antes de la resolución, los tokens se negocian a precios entre cero y uno, que pueden interpretarse como probabilidades implícitas. El precio observado, sin embargo, no garantiza que una orden se ejecute a ese mismo precio: importan el instante de la decisión, el spread, la comisión y la liquidez disponible [1, 2, 17].

El problema de decisión tiene cuatro acciones: `WAIT` (esperar o mantener), `BUY_YES`, `BUY_NO` y `SELL`. Cada mercado proporciona una secuencia de hasta 60 decisiones, una por minuto. Una compra reduce el saldo y crea una posición que puede venderse más tarde o liquidarse al final. Una predicción correcta del resultado no basta para obtener beneficio: la diferencia entre el valor esperado y el precio debe cubrir los costos de operar. En particular, una estrategia que identifica el lado ganador cuando faltan pocos minutos puede perder dinero si compra a un precio cercano a uno.

Pregunta de investigación: ¿alguno de los agentes PPO, DQN, CQL o BC obtiene en mercados no vistos un retorno medio por mercado superior al de estrategias simples evaluadas con la misma información, ejecución y costos? Se decidió que una mejora económicamente relevante empieza en `0,01` del monto fijo apostado por mercado, promediada sobre todos los mercados, incluidos los que no se operan. No operar es una decisión válida y una referencia indispensable.

El problema interesa al trading algorítmico porque obliga a decidir una secuencia de órdenes bajo costos e información retrasada; a los mercados de predicción porque permite estudiar cuánto valor adicional queda después de incorporar sus probabilidades; y a la investigación en RL porque exige separar la política

aprendida de artefactos del simulador. El alcance es exclusivamente académico: se reproducen mercados ya resueltos, con saldo ficticio y sin conexión a una wallet ni operaciones en vivo. La conclusión se limita a la familia horaria de BTC, la grilla de un minuto y el modelo de ejecución definido aquí.

Se plantearon tres hipótesis iniciales: (H1) PPO supera al mejor baseline fuera de muestra; (H2) penalizar el aumento del drawdown reduce el riesgo sin perder retorno; y (H3) el aprendizaje fuera de línea con CQL iguala o supera a la mejor política que generó sus datos. La sección de resultados las contrasta con la evidencia disponible, sin tratar un resultado negativo como falla del proyecto.

2. Análisis

2.1 Datos y unidad de estudio

La unidad es un mercado horario de la serie `btc-up-or-down-hourly` (identificador de serie Gamma `10114`). Gamma aporta el mercado, los identificadores de tokens y el resultado. El endpoint CLOB `/prices-history`, solicitado con `fidelity=1`, aporta el historial del token YES con una granularidad próxima a un punto por minuto. Binance aporta velas `BTCUSDT` de un minuto para el estado observable y de una hora para contrastar el resultado. Las fuentes publican relojes y formatos distintos; por eso se conservan las respuestas crudas y se transforman antes de entrenar [2, 3].

La captura abarca del 28 de mayo de 2025 al 30 de octubre de 2026 y contiene 12 471 mercados. Después de los filtros de calidad, exclusiones de mercados usados en análisis preliminares y construcción de las variables, el conjunto evaluable contiene 12 294 mercados: 8 682 de entrenamiento, 1 861 de validación y 1 751 de test. La separación es cronológica y por mercado: ningún episodio aparece en dos conjuntos. La exploración descrita a continuación se hizo solo con los 8 683 mercados de entrenamiento disponibles antes del último filtro de variables; no se usaron validación ni test para diseñar el simulador.

Se descartaron mercados con menos de 45 puntos dentro de la hora, huecos de más de 600 segundos, precios fuera de `[0, 1]`, historial inexistente, ventana ambigua o resultado inconsistente con la vela horaria de Binance. El título del mercado, interpretado en la zona de Nueva York, define la ventana porque el campo de cierre de Gamma es incorrecto en algunos mercados antiguos. También se recortan precios y transacciones registrados después de la resolución. Estas reglas reducen errores de datos antes de que el agente los convierta en aparentes oportunidades.

2.2 Calidad, calibración y disponibilidad temporal

Casi todos los mercados de entrenamiento tienen aproximadamente 60 puntos de precio dentro de su hora. El mayor hueco típico es de 74 segundos, pero el último precio disponible en un instante de decisión tiene una antigüedad mediana de 52 segundos. Por ello, una observación que mezcla el spot reciente de Binance con el precio de Polymarket puede comparar información tomada en instantes distintos. La figura 1 muestra la distribución de puntos, huecos y antigüedad.

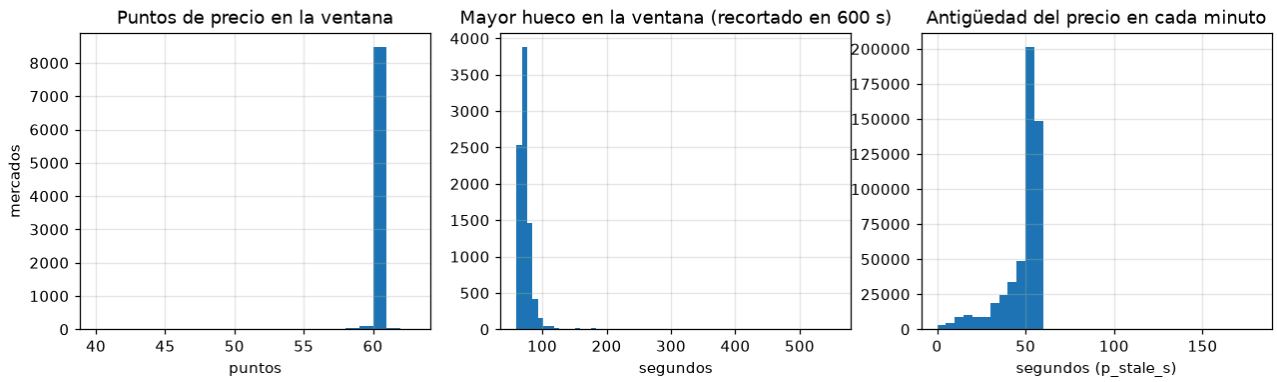


Figura 1. Calidad de la serie de precios en entrenamiento. Elaboración propia.

El precio del mercado es informativo. Si se elige el lado con precio mayor que `0,5`, el acierto observado es aproximadamente 52 % en el minuto 0, 74 % en el 30 y 92 % en el 55. El Brier score del precio disminuye durante la hora y sigue de cerca al de un valor justo calculado solo con el spot y la volatilidad. Las curvas de confiabilidad están cerca de la diagonal en los minutos 30 y 55. Estas observaciones indican que acertar el resultado a medida que avanza la hora es cada vez más fácil, pero no demuestran una oportunidad de trading después de costos.

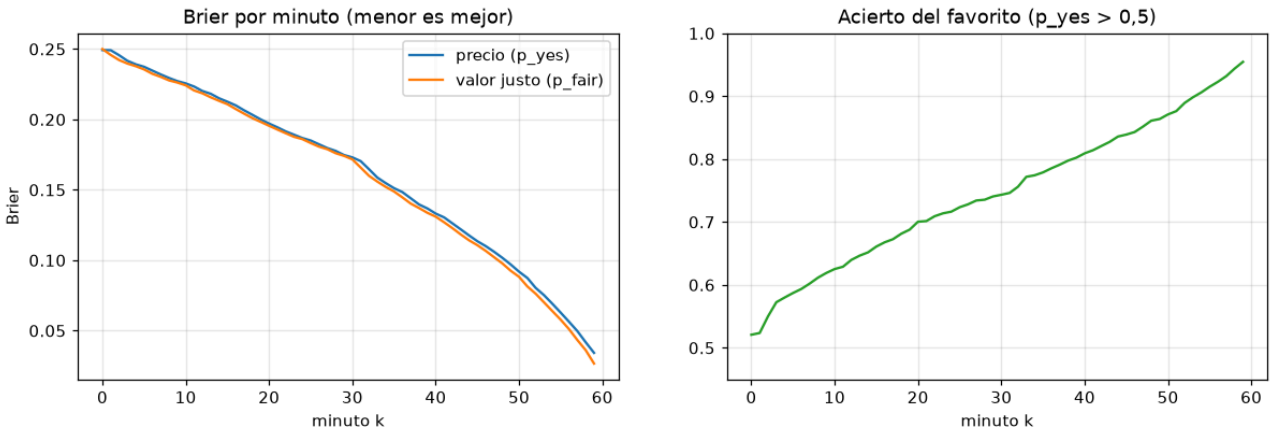


Figura 2. Brier por minuto y acierto del lado favorito; menor Brier indica mejor pronóstico. Elaboración propia.

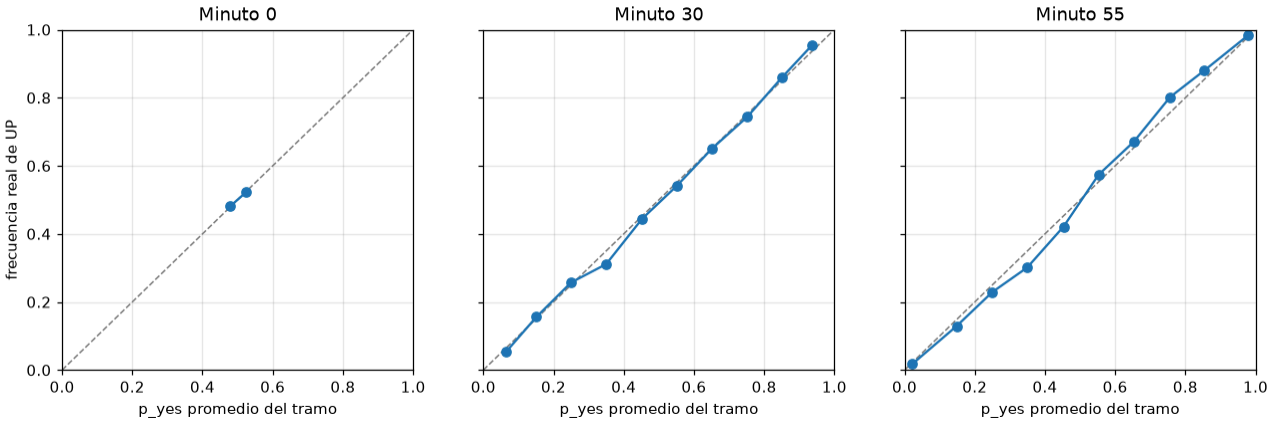


Figura 3. Frecuencia observada de UP frente al precio medio de YES; la línea diagonal representa calibración perfecta. Elaboración propia.

La correlación entre el cambio del precio de YES y el cambio del spot del minuto anterior es `0,64`; con el cambio del mismo minuto cae a `0,04`. Una comprobación preliminar con otra resolución temporal mostró que una correlación aparente de `0,90` bajaba a `0,22` al alinear los relojes. La lectura correcta es que el dato histórico llega con desfase; no se puede concluir de ello que un operador real pudiera comprar al precio atrasado.

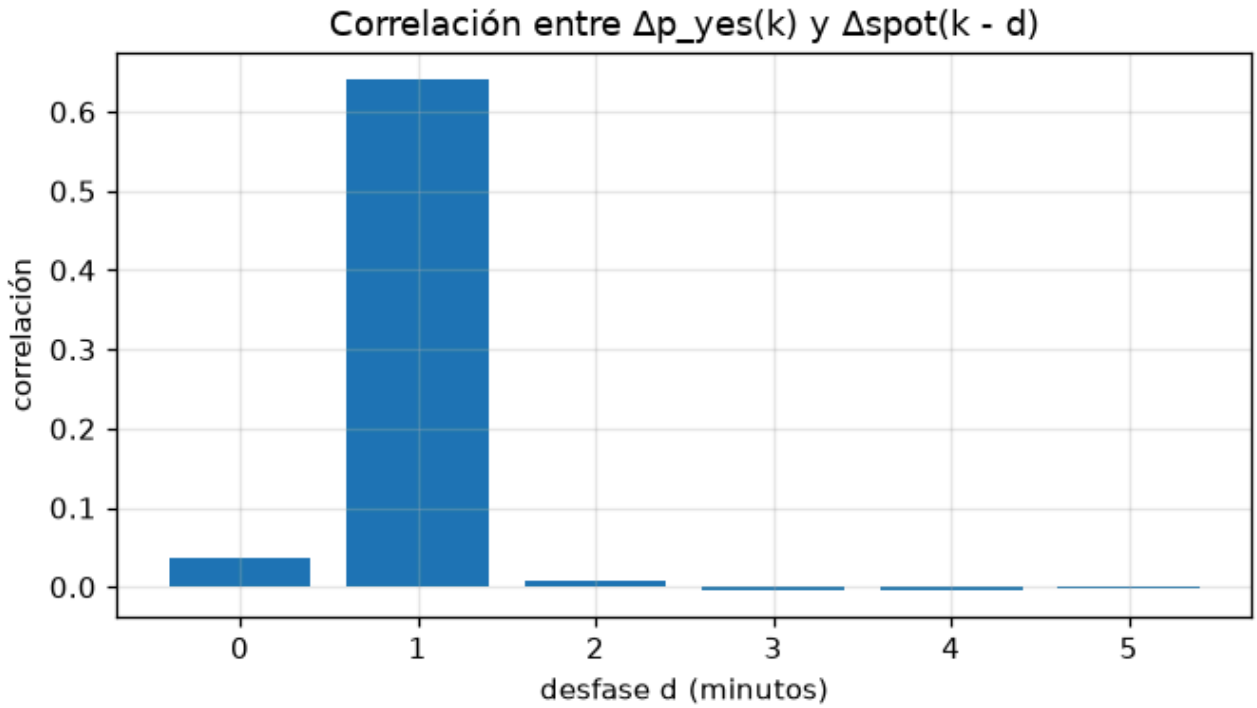


Figura 4. Correlación de los cambios de precio con cambios del spot desplazados de cero a cinco minutos. Elaboración propia.

2.3 Ventaja aparente y costo económico

Se construyó una probabilidad aproximada de UP, `p_fair = Φ(z)`, con la distancia logarítmica entre el spot actual y el precio de apertura, la volatilidad reciente y los minutos restantes. La señal `edge = p_fair - p_yes` parece ofrecer una ganancia de `0,03` a `0,16` USDC por acción al entrar al precio ya conocido en el mismo instante `t`, incluso después de costos. Esa simulación es irrealizable: el punto de precio usado para decidir puede tener casi un minuto de antigüedad. Cuando la orden se ejecuta al siguiente punto disponible, la ganancia observada baja a `0,01`– `0,02` USDC por acción **antes** de costos y se vuelve negativa **después** de ellos. La figura 5 muestra las cuatro curvas. Este hallazgo cambió la regla de ejecución del simulador y evita atribuir al agente una ventaja creada por el reloj de los datos.

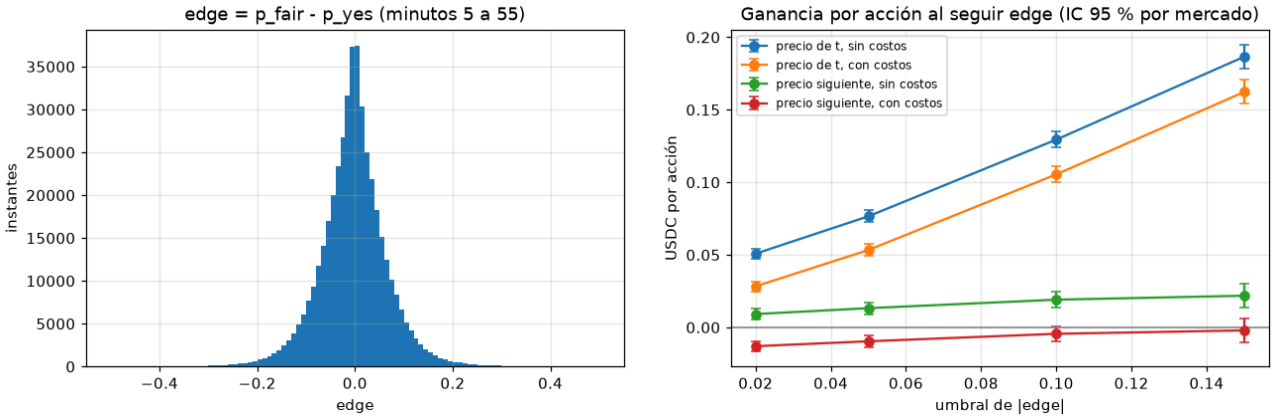


Figura 5. Ganancia al seguir `edge`: precio conocido en `t` frente al siguiente precio, antes y después de costos. Solo las curvas de precio siguiente representan la ejecución elegida. Elaboración propia.

En la configuración principal se aproxima el precio observado como punto medio, se cobra un medio spread de `0,01` por operación y una comisión taker de `0,07 × p × (1 − p)` por acción. A `p = 0,5`, entrar y mantener hasta la resolución cuesta aproximadamente `0,0275` USDC por acción, un `5,5 %` del precio medio de `0,5`;

entrar y salir antes cuesta aproximadamente el doble si el precio no cambia. Por eso una señal pequeña y estadísticamente real puede carecer de utilidad económica. La forma de la comisión se contrastó con la tabla oficial de Polymarket [1].

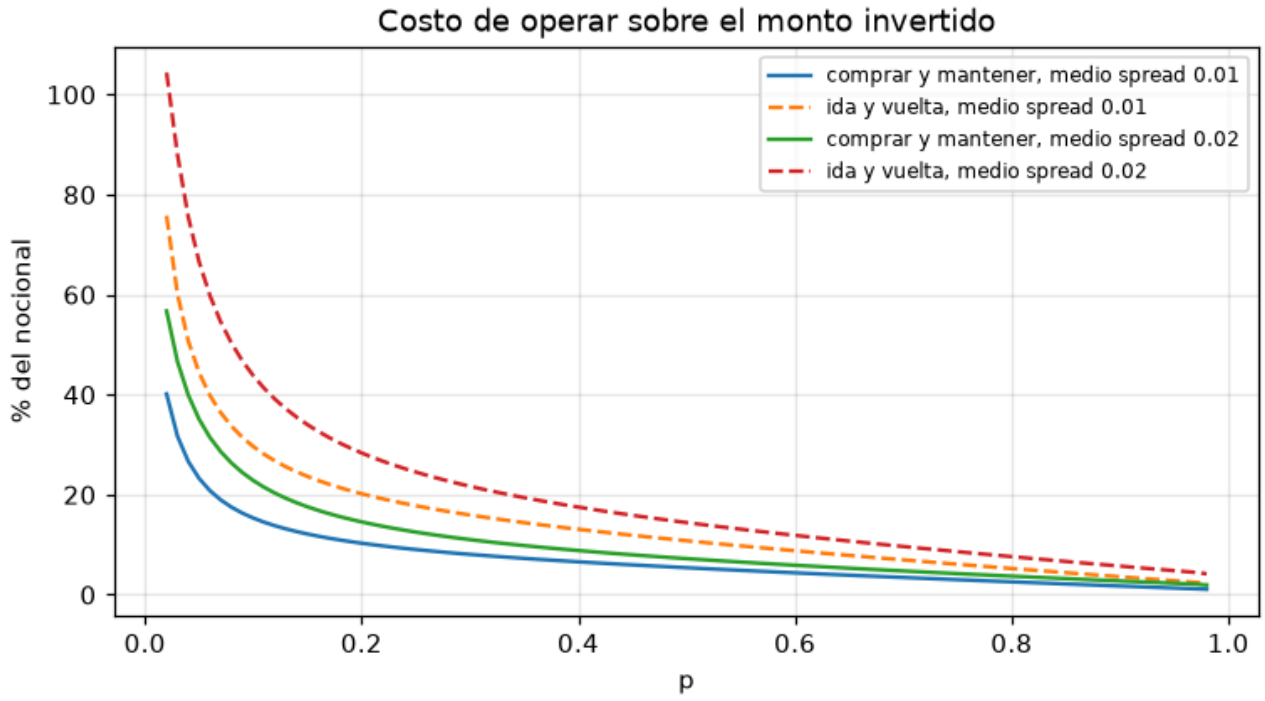


Figura 6. Costos relativos según el precio y dos supuestos de medio spread. La gráfica ilustra por qué entrar cerca de `p = 0,5` exige una ventaja sustancial. Elaboración propia.

Los mercados antiguos de entrenamiento y los recientes de validación/test pertenecen a regímenes históricos de comisión distintos. Se aplicó la misma comisión vigente a todos los conjuntos para que el experimento compare políticas bajo un costo uniforme; esto mejora la comparabilidad, pero separa el experimento de las condiciones históricas reales de una parte de entrenamiento. La calibración del precio fue similar en las dos submuestras de entrenamiento.

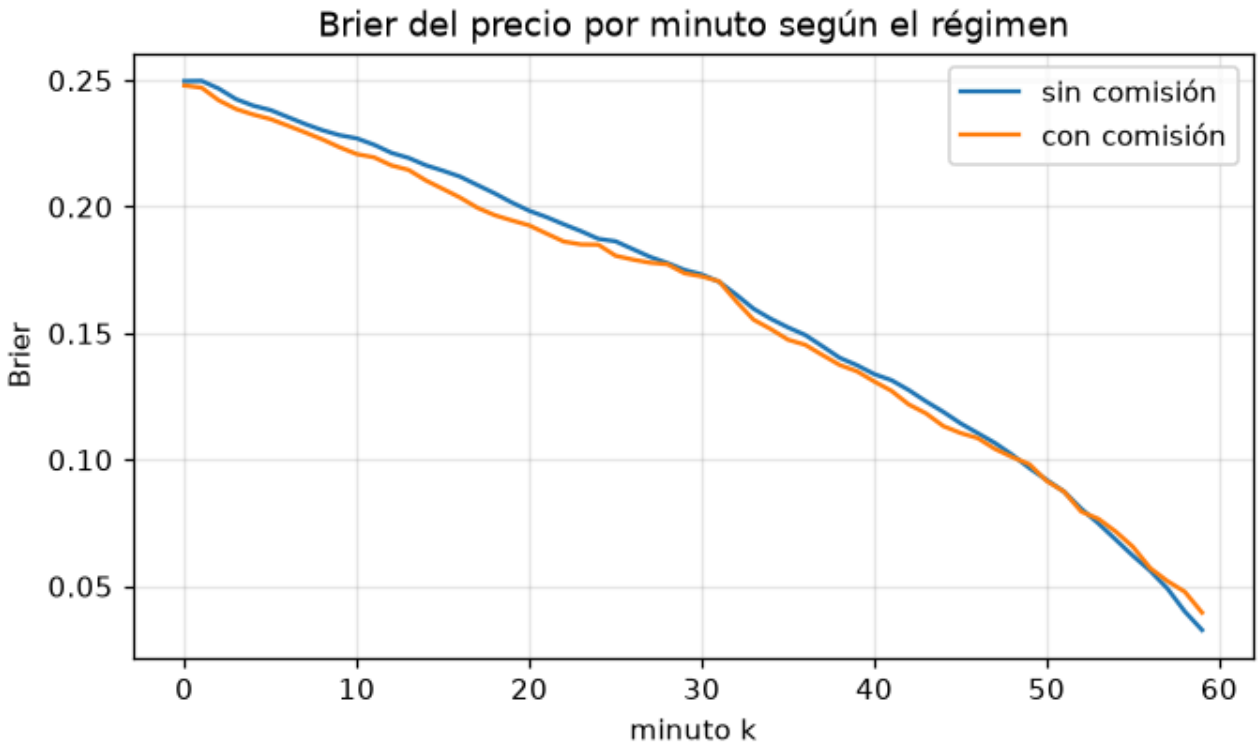


Figura 7. Brier del precio durante la hora, separado por régimen histórico de comisiones dentro de entrenamiento. Elaboración propia.

No se encontró un sesgo robusto en la frecuencia de UP por hora de Nueva York ni por día de la semana. Las pruebas de permutación dieron valores `p = 0,18` y `p = 0,32`, respectivamente. No se incluyeron reglas basadas solo en calendario.

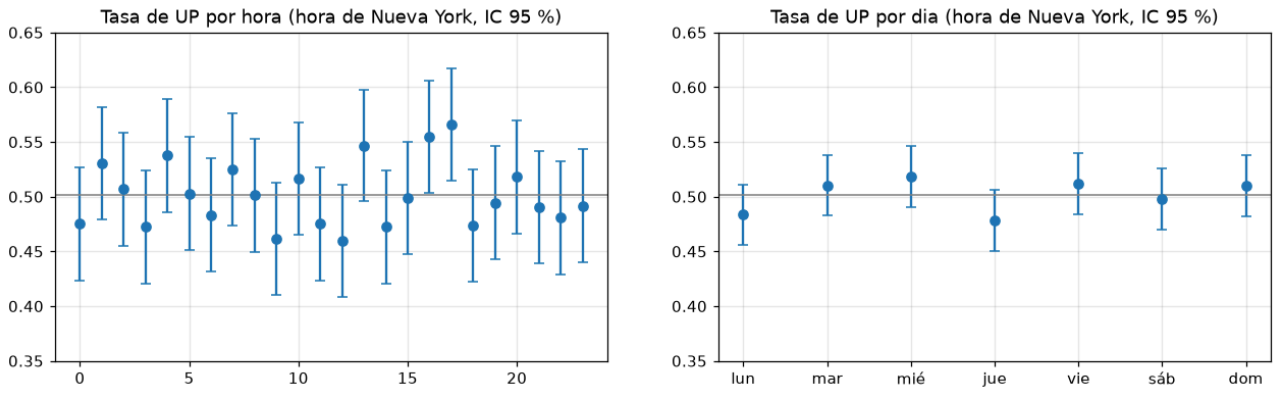


Figura 8. Frecuencia de UP por hora y día, con intervalos del 95 %. Elaboración propia.

2.4 Supuestos y riesgos del análisis

Supuesto o riesgo	Evidencia y tratamiento	Consecuencia para la interpretación
El historial representa un precio ejecutable	El CLOB no proporciona el libro histórico completo. Se suma spread y se exige un punto posterior a la decisión; además se repite la evaluación en modo estricto con trades reales.	La simulación normal puede sobrestimar ejecuciones; el modo estricto es un control parcial de liquidez.
El resultado solo se conoce al cierre	`outcome` y el `close` horario se habilitan en `w1`; el `close` de una vela de un minuto se habilita al terminar esa vela.	Evita usar el futuro como variable de entrada.

Supuesto o riesgo	Evidencia y tratamiento	Consecuencia para la interpretación
YES y NO son complementarios	En una muestra, $\|p_yes + p_no - 1\|$ tuvo media $0{,}006$ y máximo $0{,}045$; se aproxima $p_no = 1 - p_yes$.	La aproximación puede afectar el precio de NO; el spread no sustituye una validación completa del libro.
El agente es price taker	La orden simulada usa 20 USDC y no mueve el mercado.	No se modelan impacto ni profundidad variable.
La muestra permite detectar mejoras pequeñas	Test tiene 1 751 mercados, pero muchas políticas casi nunca operan.	Se informa la diferencia mínima detectable y se distingue equivalencia de resultado inconcluso.

Síntesis del análisis: el mercado ya incorpora bastante información; la supuesta ventaja más grande proviene de un desfase entre datos. Con ejecución posterior y costos, el margen observado en una regla sencilla desaparece. Esto justifica entrenar agentes capaces de abstenerse, pero también exige aceptar que la mejor política puede ser no operar.

3. Propuesta de solución

3.1 Por qué aprendizaje por refuerzo

La decisión es secuencial: comprar ahora cambia la cartera y restringe las acciones futuras; esperar conserva liquidez y puede ser mejor que acertar un resultado pagando un precio excesivo. El resultado final llega al resolver el mercado y los costos aparecen al entrar o salir. El RL permite aprender una política que considera estado, posición y tiempo restante en cada minuto. Una predicción supervisada del resultado, por sí sola, todavía necesitaría reglas para elegir el momento y el umbral de operación. Esa alternativa se conserva como baseline `FairValue`, junto a `Favorite`, `Momentum`, `MeanReversion`, `Random` y `NoTrade`.

3.2 Proceso de decisión

Componente	Definición implementada
Episodio	Una vela horaria $[w0, w1)$ de un mercado BTC Up or Down.
Decisiones	$t_k = w0 + 60k$ segundos, $k = 0,\ldots,59$.
Observación	16 números: 13 variables de mercado disponibles en t_k y 3 variables de cartera.
Acciones	`WAIT`, `BUY_YES`, `BUY_NO`, `SELL`; una posición abierta como máximo.
Tamaño	Cada compra compromete 20 USDC de un saldo inicial ficticio de 1 000 USDC.
Transición	La orden usa el primer precio posterior a $t + 2\ s$ y no más tarde que $t + 60\ s$; si falta, no se ejecuta. Compra a medio más $0{,}01$, venta a medio menos $0{,}01$, con comisión taker.
Restricciones	Una acción incompatible con la cartera se transforma en `WAIT`. No se abren posiciones en los últimos dos minutos.
Resolución	En $w1$, el token ganador paga 1 y el perdedor 0; no se simula una venta de cierre.
Descuento	$\gamma = 0{,}999$, para que el resultado al cabo de una hora conserve peso en el aprendizaje.

La observación no constituye un estado perfectamente markoviano: no se ve el libro de órdenes y el precio disponible llega con retraso. La antigüedad del precio y los cambios recientes resumen parte de esa historia. La implementación solo permite leer un campo cuando su `ts_available` es menor o igual al instante de

decisión.

3.3 Recompensa y algoritmos

Se compararon recompensas de PnL incremental, PnL valorado a precio medio, recompensa solo al final, utilidad cóncava y penalizaciones por aumento de drawdown o por mantener una posición. La configuración elegida en validación fue `pnl_risk` sobre `pnl_mid`, con $\lambda_{dd} = 1$. Si M_t es la cartera valorada a precio medio, V_t su valor realizable después de costo de venta y $DD_t = \max_{u \le t} V_u - V_t$, la señal por paso es:

$r_t = (M_t - M_{t-1}) / V_0 - \lambda_{dd} \cdot \max(0, DD_t - DD_{t-1}) / V_0$, con $V_0 = 1\,000$.

El PnL incremental da una señal más frecuente que esperar únicamente el resultado final. La teoría de recompensa por potencial ayuda a razonar sobre ese diseño [4], pero aquí $\gamma = 0{,}999$ y la penalización por drawdown cambian la función objetivo; no se afirma equivalencia exacta de políticas óptimas. La ablación empírica, no una garantía teórica, decide la variante usada.

Algoritmo	Tipo y función en el experimento	Riesgo que permite observar
PPO	RL en línea, actor crítico, política principal; actualiza una política con cambios acotados [5].	Si una política directa aprende cuándo abstenerse.
DQN	RL en línea, aprende $Q(s,a)$ para cuatro acciones discretas con memoria de experiencias y red objetivo [6].	Si la estimación de valor ofrece una alternativa a PPO.
CQL	RL fuera de línea; aprende de transiciones fijas y penaliza valores de acciones poco respaldadas por los datos [7].	Si el aprendizaje conservador usa mejor los datos históricos recolectados por heurísticas.
BC	Imitación de las acciones del dataset fijo.	Si CQL aporta algo más que copiar a las políticas recolectoras.

PPO y DQN interactúan con un simulador que reproduce precios históricos: por eso siguen siendo RL en línea respecto del entorno. CQL y BC reciben un conjunto fijo de transiciones generado antes por baselines con exploración $\varepsilon = 0{,}2$ y no eligen nuevas experiencias durante el entrenamiento.

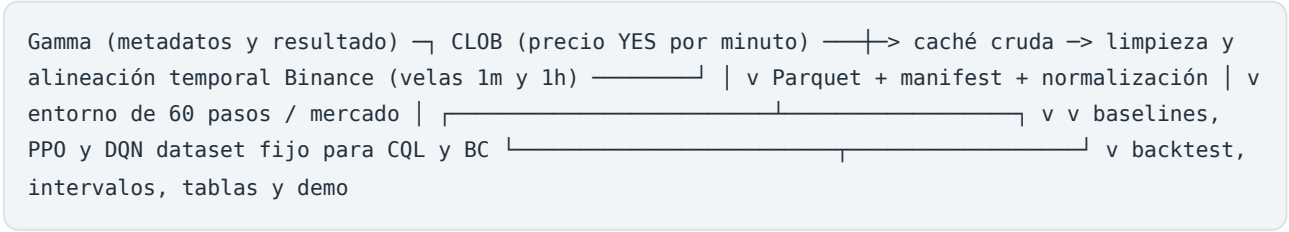
3.4 Criterio de éxito

Todos los agentes y baselines pasan por el mismo entorno, con la misma observación, tamaño de orden y costos. El baseline principal se elige en validación: se conserva `NoTrade` salvo que una heurística lo supere con su intervalo del 95 % por encima de cero. Se entrenan cinco semillas por agente; test se abre una sola vez con configuraciones congeladas. Se mide la diferencia pareada de retorno por mercado y se reportan también actividad, costos y riesgo. Los detalles y resultados están completos en la sección 6.

4. Descripción de la solución

4.1 Flujo completo y datos persistidos

El sistema es un paquete Python con etapas separadas. El flujo implementado es:



Las respuestas originales se guardan en una caché local: si ya existe el archivo crudo, la reconstrucción evita repetir la solicitud de red. El dataset procesado contiene `markets.parquet` (identidad, ventana, resultado y split), `prices_raw.parquet` (puntos CLOB sin re-muestrear), `spot_1m.parquet` (velas spot) y `steps.parquet` (las 60 observaciones por mercado), además de estadísticas de normalización y un `manifest.json` con conteos y hashes. La validación de esquemas rechaza precios fuera de rango y columnas no declaradas. Las variables con z-score se ajustan solo con entrenamiento.

Se distingue `ts_event` (cuándo ocurrió un dato) de `ts_available` (cuándo pudo utilizarse). La vela de un minuto de Binance solo entrega su cierre al terminar; el resultado horario solo existe en `w1`. En cada decisión se busca hacia atrás el último dato disponible, sin rellenar con observaciones futuras. El precio necesario para ejecutar una orden se busca **después** de la decisión. Esa separación entre observación y ejecución fue el cambio técnico más importante del proyecto.

Los timestamps del CLOB se leen en segundos Unix y los tiempos de las velas de Binance se convierten desde milisegundos a segundos Unix en UTC antes de alinearlos. Se conserva por separado la hora de apertura de una vela y el momento en que su cierre pasa a estar disponible.

4.2 Observación del agente

La observación tiene 16 entradas. Las primeras 13 describen el mercado y las tres últimas la cartera. La tabla fija su significado, de modo que el modelo puede entenderse sin consultar el código.

Entradas	Definición
`p_yes`	Último precio disponible de YES.
`dp_1`, `dp_5`	Cambio del precio de YES en uno y cinco minutos.
`p_stale`	Antigüedad del último precio, dividida por 300 segundos y limitada a 1.
`x`	`ln(spot / spot_open)`, distancia al precio de referencia de la vela.
`r_1`, `r_5`	Retornos logarítmicos del spot en uno y cinco minutos.
`sigma`	Desviación de los retornos spot de un minuto en la hora previa.
`tau`	Fracción de la hora restante.
`z`	`x / (sigma · √minutos_restantes)`, recortado a `[-5, 5]`.
`p_fair`	`Φ(z)`, probabilidad aproximada bajo un paseo aleatorio sin deriva.
`edge`	`p_fair − p_yes` calculado en el instante de decisión.
`edge_tp`	La misma diferencia con el valor justo calculado en el instante del último punto de precio.
`pos_side`, `entry_price`, `upnl`	Lado de la posición (`−1`, `0`, `1`), precio de entrada y PnL no realizado.

`edge` mezcla un spot más fresco con un precio potencialmente viejo; se conserva como señal observable, pero no se ejecuta al precio viejo. `edge_tp` permite separar parte del desfase de una posible diferencia de valoración. La volatilidad y los retornos se normalizan con media y desviación calculadas exclusivamente en entrenamiento.

4.3 Entorno, costos y verificación de órdenes

El entorno implementa la interfaz `reset/step` de Gymnasium [8]. Cada llamada a `step` devuelve la nueva observación, la recompensa, el fin del episodio y un registro de la acción solicitada, acción ejecutada, precio, comisión y cartera. Una compra usa 20 USDC incluidos los costos; se permite una posición. Comprar teniendo posición, vender sin posición o intentar abrir una en los últimos dos minutos produce `WAIT`. El entorno también expone una máscara de acciones válidas, aunque el experimento principal entrena PPO sin máscara para mantener condiciones comparables con DQN y CQL.

Para un token de precio medio `p`, el precio de compra es `min(max(p + h, tick), 1 − tick)` y el de venta es `max(min(p − h, 1 − tick), tick)`, con `h = 0,01` y `tick = 0,001`. La comisión es `acciones × 0,07 × [p · (1 − p)]`, calculada sobre el precio de la operación, redondeada a cinco decimales y llevada a cero si queda por debajo de `0,00001` USDC. El modo exacto de redondeo de órdenes con múltiples ejecuciones no está documentado públicamente; el simulador usa redondeo al más cercano con mitades hacia arriba. En `w1` se liquida la posición a 1 o 0 sin simular otra operación. El saldo no puede ser negativo ni hay apalancamiento [1].

El precio histórico no prueba por sí mismo que hubiese liquidez suficiente. Por eso se reportan dos modos. El **normal** acepta el primer punto de precio después de `t + 2 s` y hasta `t + 60 s`. El **estricto** exige además un trade taker observado del mismo lado, a ese precio o mejor, por al menos 20 USDC dentro de la ventana; de otro modo la orden se marca como no verificable. Esta comprobación es conservadora y tampoco reproduce el libro de órdenes completo.

4.4 Entrenamiento, selección y evaluación

Se compararon configuraciones en validación antes de fijar los modelos finales. PPO y DQN se entrenaron con 500 000 pasos; CQL con 200 000 actualizaciones y BC con 50 000. Cada configuración final usa una red de dos capas de 64 neuronas, $\gamma = 0{,}999$, cinco semillas (0 a 4) y diez checkpoints por semilla. La búsqueda inicial probó ocho configuraciones de PPO, ocho de DQN, seis de CQL y tres de BC con dos semillas por punto. La tabla recoge los parámetros finales más relevantes.

Algoritmo	Tasa de aprendizaje	Parámetros distintivos
PPO	`0,0003`	`n_steps = 512`, lote 256, entropía `0,01`, cuatro entornos.
DQN	`0,0003`	memoria `100 000`, aprendizaje tras `5 000` pasos, lote 64, red objetivo cada `2 000` pasos, fracción de exploración `0,1`.
CQL discreto	`0,0001`	lote 256, penalización conservadora $\alpha = 0{,}5$, red objetivo cada `2 000` pasos.
BC discreto	`0,0003`	lote 256; imitación de acciones del dataset fijo.

El dataset fijo de CQL y BC se recolectó en entrenamiento mediante `Favorite`, `Momentum`, `MeanReversion`, `FairValue` y `NoTrade`, con $\varepsilon = 0{,}2$. El mejor checkpoint de cada semilla se escogió por retorno medio en validación. Los baselines también ajustaron sus umbrales en ese conjunto. Test se reservó para la evaluación final.

La implementación usa pruebas unitarias para esquemas, conservación de dinero, acciones inválidas, alineación temporal, costos y métricas, más una prueba de integración sobre un dataset pequeño. Una CI ejecuta análisis estático, tipos, pruebas con umbral de cobertura del 70 % y entrenamientos de humo. Configuraciones YAML, semillas y hashes del dataset ayudan a repetir el experimento. Los comandos principales son `make capture`, `make capture-spot`, `make dataset`, `make eda`, `make collect-offline`, `make train`, `make report` y `make check`. La demo local reproduce un mercado histórico con acciones, precios y saldo simulado; no realiza operaciones reales.

4.5 Evolución de la implementación

La propuesta inicial planteaba descargar precios y entrenar PPO/DQN sobre mercados binarios. El primer estudio de APIs cambió el alcance a BTC horario porque esa serie tenía suficientes episodios y una regla de resolución contrastable con Binance. La EDA encontró el atraso del precio y obligó a distinguir el dato visible del precio ejecutable. Una revisión de trades mostró que tampoco bastaba un spread fijo para afirmar que una orden podría llenarse, por lo que se añadió el modo estricto. La investigación de recompensas llevó a una ablación; la penalización de drawdown fue seleccionada en validación, con la advertencia de que su mejora se debía en gran parte a operar menos. Por último, se congelaron el protocolo, las configuraciones y los baselines antes de abrir test. Cada cambio responde a una observación o una prueba, no al resultado final deseado.

5. Herramientas aplicadas e IA generativa

Como no se dispone aquí de una lista verificable de herramientas vistas en clase, se explican en detalle todas las piezas especializadas que fueron decisivas para reproducir y evaluar la solución.

5.1 Fuentes y herramientas de ingeniería

Herramienta	Qué hace y cómo se aplicó	Por qué fue necesaria y cómo se verificó
Gamma y CLOB de Polymarket	Gamma identifica la serie, la ventana, el token YES y el resultado; CLOB `/prices-history` devuelve pares `(t,p)` con `startTs`, `endTs` y `fidelity=1`. Las respuestas se archivan antes de transformarlas [2].	El historial fino de mercados cerrados no salió de la ruta Data API v2 probada inicialmente. Se midieron granularidad y huecos en mercados antiguos y recientes; se validaron precios y resultados.
API Spot de Binance	`/api/v3/klines` aporta velas `BTCUSDT` de 1 minuto y 1 hora [3]. La de 1 minuto alimenta el estado solo al cerrar; la horaria verifica el resultado del mercado.	Evita inferir el resultado de un precio de Polymarket posterior al cierre y obliga a alinear correctamente dos fuentes. Se contrastaron resultados con las velas.
Gymnasium	Define el contrato de entorno: `reset` inicializa un mercado y `step` recibe una acción y devuelve observación, recompensa y estado final [8].	Permite que PPO y DQN interactúen con el mismo simulador que usan los baselines. Se verificaron formas de observación, reinicio, fin y invariantes.
Stable Baselines3	Implementa PPO y DQN con redes multicapa, checkpoints, semillas y parámetros configurables [9]. PPO actualiza directamente una política; DQN usa memoria de experiencias y una red objetivo.	Evitó reimplementar algoritmos estándar y concentró la validación en el entorno. Se compararon checkpoints y se hicieron corridas de humo.
d3rlpy	Implementa CQL discreto y BC discreto sobre transiciones fijas; α controla la penalización conservadora de CQL [10].	Hace explícita la comparación entre aprendizaje fuera de línea e imitación. Se comprobó que el dataset de transiciones se construyera solo con entrenamiento.
Pandera y Parquet	Pandera valida esquemas, tipos y rangos de las tablas [11]; Parquet guarda las tablas procesadas.	Impide que un precio imposible, una columna inesperada o datos sin tiempo de disponibilidad entren al experimento. Los tests prueban contratos y errores conocidos.
uv y configuraciones YAML	`uv.lock` fija versiones y `uv sync`/`uv run` instalan o ejecutan el proyecto [12]. YAML separa dataset, costos, recompensa y entrenamiento del código.	Reduce diferencias entre máquinas y deja auditable la configuración final. Se guardan semillas y hashes para comprobar el dataset.

Herramienta	Qué hace y cómo se aplicó	Por qué fue necesaria y cómo se verificó
GitHub Actions, pytest, Ruff y mypy	La CI ejecuta formato, lint, tipos, cobertura y pruebas de humo [13].	Detecta regresiones del pipeline, del entorno y de la evaluación. El umbral configurado de cobertura es 70 %; no sustituye la revisión estadística del resultado.
Streamlit	Presenta la reproducción local de un mercado, sus decisiones y el saldo ficticio [14].	Permite inspeccionar una trayectoria paso a paso y comunicar el funcionamiento sin habilitar trading real.

5.2 Uso crítico de IA y evolución de la idea

Se usó Claude Code para explorar APIs, redactar hipótesis técnicas, implementar y revisar código; Perplexity para investigación con fuentes; Context7 para consultar documentación de librerías según versión; y subagentes especializados como revisores de estadística, plan y fuga temporal [15, 16]. Codex ayudó a reunir y redactar este informe único a partir del material del proyecto. La IA no fue fuente de métricas: cada cifra del informe procede del dataset, la EDA o los reportes calculados por el proyecto. Una persona aceptó o rechazó las propuestas, comparó respuestas con documentación original y exigió pruebas cuando una corrección afectaba el código.

La tabla recoge los prompts relevantes conservados durante el trabajo. Las comillas indican texto registrado literalmente; «resumen» indica que no se conservó la formulación completa y evita inventarla. P10 y P13 se transcriben íntegros después de la tabla porque determinaron costos y recompensa.

ID y herramienta	Prompt o resumen fiel	Resultado, evaluación y aporte
P1, Claude Code	“quiero ver cómo integrar API, cómo jalar data, pasar por ETL si hace falta, explorar y dejar input y generar diseño para entrenar modelo”	Satisfactorio. Consultas reproducibles a las APIs mostraron la granularidad útil y llevaron a BTC horario.
P2, Claude Code	“miremos qué skills nos pueden ayudar … agency-agents … usarla y saber con qué y por qué se usa”	Falló: creó agentes en lugar de reutilizarlos. Se corrigió el flujo y se emplearon revisores existentes.
P3, Claude Code	“determinemos qué preguntas necesitan decisión antes de hacer un diseño”	Parcial: identificó decisiones pero sin explicar su origen. Se vinculó cada decisión con una laguna de la propuesta.
P4, Claude Code	Resumen: medir calibración y Brier del precio.	Falló: Brier imposible de 25 078 por un precio corrupto de 5000,49. El rango teórico reveló el error; se filtraron precios fuera de `[0,1]`.
P5, Claude Code	Resumen: medir si el precio reacciona tarde al spot.	Satisfactorio tras revisión: una correlación de 0,90 parecía demasiado buena; otra resolución temporal la redujo a 0,22. Originó el modelo de tiempo.
P6, subagentes	“antes de responderte, que otro agente valide consecuencias de ponerle sí o más bien seguir tus sugerencias, qué perdemos y qué no por cada punto”	Satisfactorio. Detectaron tolerancia de ejecución excesiva, riesgo de contaminar test y `edge` artificial; se contrastó con datos.
P7, Claude Code + Context7	“hagamos un MCP de Context7 para que pueda usarse … y se haga código actualizado”	Satisfactorio. Las recomendaciones de versiones se verificaron con documentación y releases oficiales.
P8, Claude Code	Resumen: continuar la captura del historial crudo de mercados.	Parcial. Dos fallas de proceso y red llevaron a reintentos comprobados con test; terminó la captura de 12 471 mercados.

ID y herramienta	Prompt o resumen fiel	Resultado, evaluación y aporte
P9, Claude Code	“hagamos lo que está sin bloqueos”	Satisfactorio. Produjo la EDA de entrenamiento y ocho figuras; un `assert` comprobó que no se cargaran val/test.
P10, Perplexity	Prompt íntegro A, abajo: comisiones exactas de Polymarket.	Satisfactorio con vacíos. Se contrastaron fórmula y ejemplos con la fuente oficial y el crudo; se corrigió el tratamiento de comisiones menores que el mínimo.
P11, subagente estadístico	Resumen: criticar unidad de análisis, dependencia entre días, semillas, baseline y diferencias cero.	Satisfactorio. Detectó cuatro fallas graves y motivó bootstrap de dos niveles, potencia y clasificación simétrica.
P12, Claude Code	“¿Es correcto nuestro modelo de ejecución S4 considerando que Polymarket utiliza un CLOB? … Revisa qué datos históricos tenemos disponibles y determina si el modelo actual es realista o introduce ganancias artificiales … sin inventar liquidez que no podemos verificar”.	Satisfactorio. Una muestra de trades mostró apoyo real para solo 58 % de las ejecuciones simuladas; se creó el modo estricto.
P13, Claude Code + Perplexity	Prompt íntegro B, abajo: diseño de recompensa y literatura.	Satisfactorio con reservas. Se verificaron artículos y código; se corrigió una interpretación errónea de la recompensa. Condujo a la ablación de siete variantes.
P14, Claude Code	Resumen: revisar documentación y PR del entorno según el rol técnico.	Satisfactorio. Una prueba que fallaba confirmó configuraciones de recompensa incompletas; se exigieron parámetros explícitos.
P15, Claude Code	Resumen: integrar PR, entrenar y evaluar una vez en test.	Satisfactorio. Suite y prueba de punta a punta detectaron fallas; una medición CPU/GPU cambió la elección de cómputo.
P16, Codex, 09/11/2026	“ok entonces contruyelo. en un md en ese md debe de estar todo fotos, resultados, etc no tienes que hacer referencia a otros. la descripcion del problema ya esta , el analisis si tendras que crearlo desde 0 creo que no esta, la propuesta de la solucion cierrla y los demas ya tenes material.”	Produjo la redacción unificada y gráficos derivados de los CSV. Se contrastaron las cifras con los reportes, las afirmaciones técnicas con código y configuraciones, las fuentes externas con sus originales y las once figuras con un renderizador de Markdown.

Prompt íntegro A (P10, Perplexity, investigación de comisiones):

> Necesito información oficial y verificable sobre las comisiones (fees) de Polymarket para los mercados cripto "Bitcoin Up or Down" horarios (serie btc-up-or-down-hourly), vigentes en 2026. Prioriza la documentación oficial (docs.polymarket.com), el repositorio oficial de Polymarket en GitHub (clientes CLOB, contratos CTF Exchange) y anuncios oficiales. Cita la URL de cada dato y marca como "no confirmado" lo que no tenga fuente oficial.
>
> Responde cada punto por separado:
>
> 1. Fórmula exacta de la comisión taker para los esquemas "crypto_fees_v2" (rate 0.07, exponent 1) y "crypto_fees" (rate 0.25, exponent 2). ¿Es fee = shares × rate × (p × (1 − p))^exponent? ¿Desde qué fecha se cobra en los mercados horarios de BTC y qué esquema aplica a cada periodo?
> 2. Redondeo: ¿a cuántos decimales se redondea la comisión y con qué modo (hacia arriba, hacia abajo, al más cercano)? ¿Existe una comisión mínima (por ejemplo 0.00001 USDC)? ¿Se calcula por orden o por cada ejecución (fill) cuando una orden cruza varios niveles del libro?
> 3. Moneda en que se cobra: en una COMPRA, ¿se paga en USDC aparte del monto o se descuentan acciones de las recibidas? En una VENTA, ¿se descuenta del USDC recibido o de

las acciones?

4. Ejemplos numéricos oficiales (tabla de precio, acciones y comisión) copiados tal cual, con su URL.
5. ¿Los makers pagan comisión? ¿Qué significa "rebate_rate 0.2" y "taker_only true"?
6. Tick mínimo y límites de precio en estos mercados (¿0.001 a 0.999?) y tamaño mínimo de orden.
7. ¿Cobrar el pago de 1 USDC por acción ganadora al resolver (redeem) tiene comisión?
8. Cualquier cambio de las comisiones de mercados cripto anunciado entre 2025 y 2026, con fecha.

Prompt íntegro B (P13, Perplexity, investigación de recompensas):

> Necesito literatura académica y referencias verificables sobre el diseño de la función de recompensa en aprendizaje por refuerzo aplicado a trading. Prioriza papers con revisión por pares, arXiv con autores identificables y repositorios oficiales de GitHub. Cita la URL o el DOI de cada dato y marca como "no confirmado" lo que no tenga fuente.
>
> Contexto: un agente (PPO, DQN y CQL) opera mercados binarios de 60 pasos que pagan 1 o 0 al final, con una posición a la vez, costos de transacción (spread y comisión) y descuento gamma cercano a 1. Hoy la recompensa es el cambio del valor de la cartera en cada paso, con la posición valorada a lo que se recibiría al venderla ya, así que comprar da una recompensa negativa inmediata.
>
> Responde cada punto por separado:
>
> 1. Funciones de recompensa usadas en RL para trading: PnL absoluto, retorno logarítmico, Sharpe diferencial (Moody y Saffell), Sortino, penalizaciones por drawdown, CVaR, utilidad CARA o CRRA y penalizaciones por inventario (Cartea y Jaimungal). Para cada una: fórmula, paper original con enlace y qué problema resuelve.
> 2. Estudios que comparen empíricamente varias recompensas en el mismo entorno (ablaciones): qué compararon, con cuántas semillas y qué concluyeron.
> 3. Reward shaping basado en potencial (Ng, Harada y Russell, 1999): ¿una recompensa densa de mark-to-market conserva la política óptima respecto de la recompensa terminal? ¿Qué cambia con gamma menor que 1?
> 4. Penalizaciones por drawdown en la recompensa: cómo se definen (incremento por paso o máximo del episodio) y si hay evidencia de que castiguen la entrada o lleven a no operar.
> 5. RL en apuestas o derivados con pago binario y horizonte fijo (opciones binarias, mercados de predicción, apuestas deportivas): papers o repositorios y qué recompensa usan.
> 6. Costos de transacción y el colapso a "no operar": cómo lo evitan los papers (escala de la recompensa, entropía, currículo de costos u otros).
> 7. Escala y normalización de la recompensa en PPO y DQN (por ejemplo, VecNormalize de stable-baselines3): práctica recomendada y su efecto.
> 8. Cómo se reporta una ablación de recompensas en papers de RL para trading: semillas, métricas y pruebas estadísticas.
>
> Termina con una tabla: recompensa, fórmula, referencia y evidencia empírica a favor o en contra.

Las respuestas de IA fueron útiles cuando produjeron una pregunta verificable: consultar otra fuente, escribir un test o medir una simulación alternativa. Sus errores también cambiaron el proyecto. El precio imposible de P4 condujo a validar rangos; el falso beneficio de P5 llevó a separar reloj del spot y reloj del

mercado; P11 fortaleció la prueba estadística; y P12 mostró que la liquidez debía informarse. Este es el entendimiento final de la solución: una política de trading solo es evaluable si observación, ejecución, costos, selección de modelos y test respetan una misma línea de tiempo y una misma regla para todos.

6. Resultados y métricas

6.1 Protocolo y lectura de las cifras

La métrica principal de un mercado es `R_i = PnL_i / 20 USDC`: se divide por el monto fijo de una compra, también cuando el agente no opera (`R_i = 0`). La comparación pareada con `NoTrade` es `D_i = R_i(agente) − R_i(NoTrade)`. Como ninguna heurística superó a `NoTrade` en validación según la regla predefinida, `NoTrade` quedó como baseline principal y su retorno es cero. Se usaron cinco semillas por agente y 1 751 mercados de test distribuidos en 76 días; el plan inicial había supuesto 73 días para estimar potencia. Esa diferencia hace la estimación previa de diferencia mínima detectable ligeramente conservadora y no cambia la clasificación.

El intervalo principal remuestrea bloques de días para conservar parte de la dependencia temporal, y remuestrea además las cinco semillas para representar variación de entrenamiento. Se calcularon 10 000 réplicas y un intervalo bilateral BCa del 98,75 %, ajustado por las cuatro comparaciones principales mediante Bonferroni. Una política **supera** la referencia solo si el límite inferior es mayor que cero y la media alcanza `+0,01` del stake por mercado. Un intervalo entero dentro de `(-0,01, +0,01)` se clasifica **equivalente**; cuando no permite decidir se clasifica **inconcluso**. Estos términos son los del protocolo de este experimento: equivalencia estadística no implica que cualquier diferencia económica pequeña sea imposible.

6.2 Ablación de recompensa y selección en validación

La recompensa se eligió antes de evaluar test. En una ablación PPO de cinco semillas por variante, `pnl_risk` con `λ_dd = 1` obtuvo `+0,0012` de retorno medio del mejor checkpoint en validación, con IC del 95 % entre `+0,0001` y `+0,0023` **entre semillas**. No es el intervalo del protocolo final, que además incorpora variación temporal. Esa variante dejó sin operar el `89,3 %` de los mercados. Las variantes que más operaban perdieron varios puntos porcentuales del stake por mercado.

Recompensa PPO	Retorno medio del mejor checkpoint en val	Mercados sin operar
`pnl_risk`, base `pnl_mid`, `λ_dd = 1`	+0,0012	89,3 %
`pnl_risk`, base `pnl_mid`, `λ_dd = 0,5`	+0,0001	76,8 %
`utility`	−0,0307	10,9 %
`pnl_mid`	−0,0348	4,8 %
`pnl`	−0,0358	1,8 %
`pnl_hold`	−0,0373	5,5 %
`terminal`	−0,0673	3,4 %

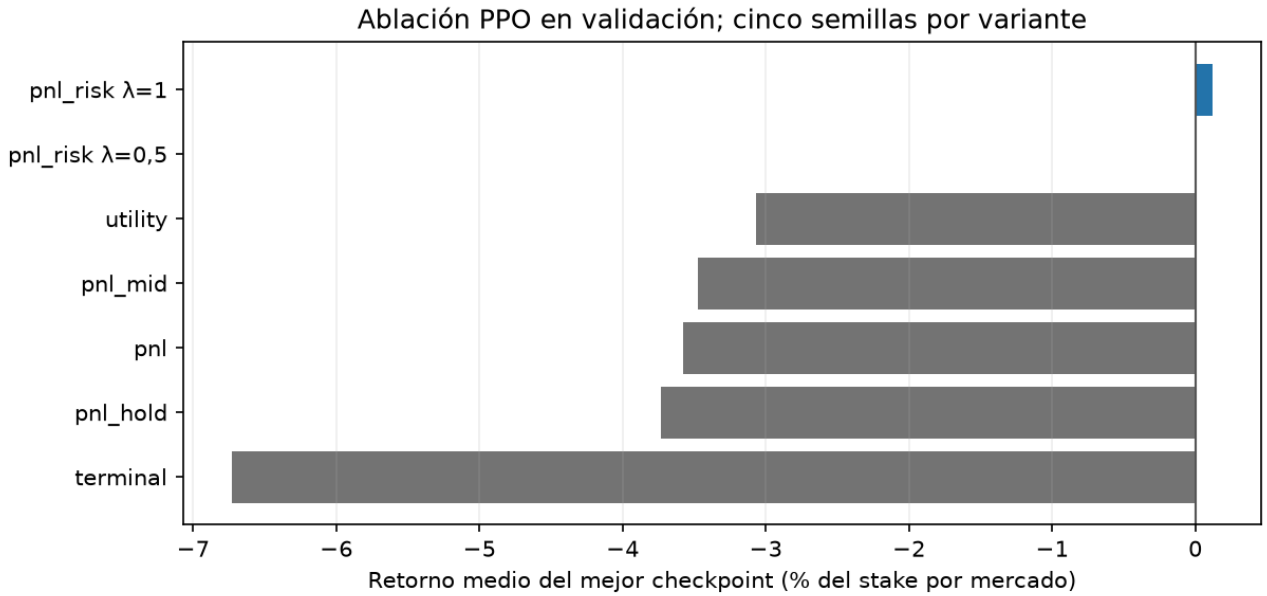


Figura 9. Ablación de la recompensa, usando el mejor checkpoint de cada semilla en validación. Elaboración propia a partir de los resultados del entrenamiento.

La selección muestra que la penalización de riesgo produjo una política más cautelosa; no prueba que el drawdown haya disminuido **sin** sacrificar retorno. El beneficio observado en validación podría proceder de abstenerse con frecuencia. Por eso el resultado definitivo se toma de test.

6.3 Comparación principal en test

La tabla muestra la diferencia media `D` en unidades del stake por mercado, su intervalo ajustado y la clasificación. El modo estricto anula órdenes sin apoyo de un trade real; no vuelve a entrenar el agente. Los valores se redondean a cuatro decimales, y una cota mostrada como `0,0000` puede ser levemente distinta de cero antes del redondeo.

Agente	Modo	Media de `D`	IC 98,75 %	Clasificación	Mercados con `D ≠ 0`
PPO	Normal	−0,0005	[−0,0029; +0,0018]	Equivalente	664
PPO	Estricto	−0,0011	[−0,0037; +0,0006]	Equivalente	479
DQN	Normal	−0,0018	[−0,0082; +0,0036]	Equivalente	1 466
DQN	Estricto	−0,0033	[−0,0110; +0,0002]	Inconcluso	1 409
CQL	Normal	−0,0126	[−0,0263; −0,0027]	Inferior	144
CQL	Estricto	−0,0102	[−0,0197; −0,0048]	Inferior	79
BC	Normal	−0,0014	[−0,0050; −0,0000]	Peor, pero no relevante	23
BC	Estricto	−0,0012	[−0,0043; +0,0000]	Equivalente	18

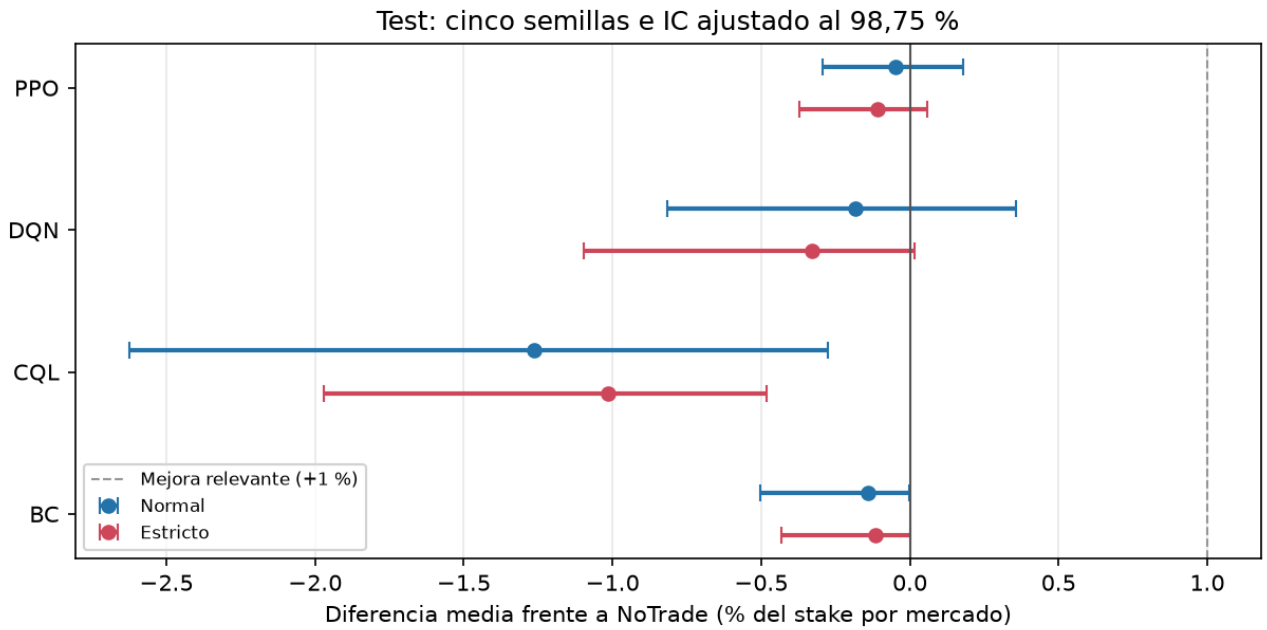


Figura 10. Diferencia respecto de `NoTrade` y sus intervalos ajustados. La línea punteada marca la mejora mínima relevante de +1 % del stake por mercado; ningún intervalo la respalda. Elaboración propia.

Ningún agente cumplió el criterio de superioridad. PPO y DQN quedaron equivalentes a no operar en modo normal; CQL fue inferior en ambos modos. DQN cambió de equivalente a inconcluso al exigir ejecuciones respaldadas por trades, de modo que su clasificación depende de la hipótesis de liquidez. BC operó en solo 23 mercados con diferencia distinta de cero en modo normal y 18 en modo estricto: con menos de 30 mercados informativos, su intervalo no se considera confiable. La diferencia mínima detectable estimada fue `0,0129` para BC y `0,0737` para CQL, mayores que el umbral relevante de `0,0100`; el experimento tiene poca potencia para detectar una mejora de ese tamaño en esos algoritmos.

La caída entre validación y test es especialmente clara en CQL: pasó de `+0,0109` en val a `−0,0126` en test, en modo normal. Su intervalo de validación incluía cero; por tanto, ese valor alto no era una ventaja confirmada. Seleccionar configuraciones y checkpoints por el mismo conjunto de validación puede favorecer un resultado optimista, aun sin mirar test.

6.4 Magnitud económica, actividad, riesgo y costos

Las métricas de PPO, DQN, CQL y BC de la tabla siguiente son la **media simple de las cinco semillas** de cada política en modo normal. Las filas de baselines son una corrida por estrategia, excepto `Random`, cuyo resultado mostrado es la corrida registrada en el reporte. `PnL total` y drawdown están en USDC sobre la secuencia de los 1 751 mercados; Sharpe es la media dividida por la desviación de retornos **por mercado**, sin anualizar. – indica que la métrica no está definida para todas las semillas, por ejemplo cuando BC no opera.

Política	Retorno medio / stake	PnL total (USDC)	Sharpe	Drawdown máx. (USDC)	Aciertos entre mercados operados
PPO	−0,0005	−16,76	−0,013	41,82	85,7 %
DQN	−0,0018	−64,30	−0,014	119,24	79,3 %
CQL	−0,0126	−442,96	−0,071	499,78	18,7 %
BC	−0,0014	−48,70	—	48,80	—
NoTrade	0	0	—	0	—
FairValue	−0,0214	−750,54	−0,031	982,33	45,4 %

Política	Retorno medio / stake	PnL total (USDC)	Sharpe	Drawdown máx. (USDC)	Aciertos entre mercados operados
Favorite	−0,0311	−1 087,52	−0,045	1 275,63	68,4 %
Momentum	−0,0854	−2 992,24	−0,203	3 005,67	51,1 %
MeanReversion	−0,2961	−10 368,64	−0,323	10 372,40	25,1 %
Random	−1,4988	−52 486,35	−0,654	52 486,35	11,4 %

La tasa alta de aciertos de PPO y DQN no equivale a rentabilidad. La métrica cuenta solo el signo del PnL de mercados operados; el retorno medio incluye tamaño de ganancias y pérdidas, costos y mercados sin operar. `Random` puede perder más del 100 % del *stake* de referencia por mercado porque realiza muchas operaciones, mientras que el denominador permanece fijo en 20 USDC.

Política	Órdenes ejecutadas por mercado	Mercados sin operar	Comisiones (USDC)	Spread (USDC)	Acciones inválidas	Ejecuciones verificadas
PPO	0,125	88,8 %	12,50	29,72	46,5 %	52,7 %
DQN	0,352	72,1 %	73,14	142,48	59,1 %	51,2 %
CQL	0,060	96,9 %	109,60	354,59	≈0 %	58,0 %
BC	0,004	99,7 %	5,39	17,57	0 %	—
FairValue	0,260	74,0 %	329,92	345,09	<0,1 %	53,5 %
Favorite	0,983	1,7 %	729,54	506,46	0 %	39,9 %

Las comisiones y el spread son sumas a lo largo de test; para agentes se promedian las sumas de las cinco semillas. El porcentaje de acciones inválidas usa todas las decisiones pedidas, no solo órdenes enviadas. En PPO y DQN es elevado porque la política puede solicitar comprar con posición abierta o vender sin ella; el entorno convierte esas solicitudes en `WAIT`. La columna de ejecuciones verificadas muestra otra limitación: aproximadamente la mitad de las ejecuciones normales de PPO y DQN tienen apoyo en los trades disponibles. En el modo estricto las ejecuciones que quedan son verificadas por construcción, pero la ausencia de trade observado no demuestra que una orden real habría sido imposible.

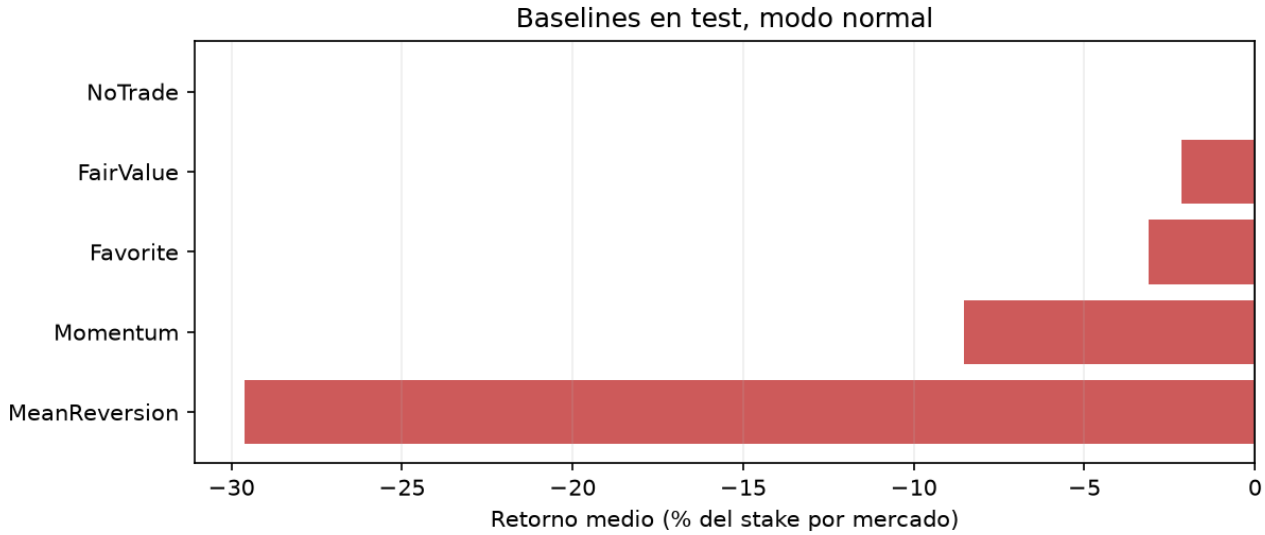


Figura 11. Retorno medio de las heurísticas y de `NoTrade` en test, modo normal. Se omite `Random` de la figura para mantener legible la escala; su cifra figura en la tabla. Elaboración propia.

6.5 Sensibilidad y alcance de los resultados

El análisis exploratorio comparó precios de ejecución y curvas teóricas de costo para medios spreads de `0,01` y `0,02` (figuras 5 y 6). La evaluación final sí repitió las políticas en modo normal y estricto. **No hay en los reportes una corrida final reentrenada sin comisión ni una curva de retorno del mejor agente frente a varios spreads.** Por ello no se atribuye de manera causal todo el resultado negativo a la comisión ni se presenta una sensibilidad de desempeño del agente que no se midió. Los números de test responden a la configuración principal: medio spread `0,01`, comisión cripto uniforme y latencia de dos segundos seguida del primer precio disponible en un máximo de 60 segundos.

7. Conclusión

La respuesta a la pregunta del proyecto es **no se demostró que un agente de RL supere al mejor baseline**, que resultó ser `NoTrade`, en los 1 751 mercados de test. PPO y DQN obtuvieron diferencias pequeñas y equivalentes a cero según el umbral fijado en modo normal; CQL fue inferior. La conclusión se sostiene bajo el protocolo predefinido y debe leerse con los límites de potencia y de liquidez indicados. No equivale a demostrar que ninguna estrategia de trading pueda funcionar en Polymarket.

La hipótesis H1 no se cumplió: PPO no superó a `NoTrade`. La ablación de H2 favoreció en validación la recompensa con penalización de drawdown, pero su efecto dominante fue reducir la actividad; con la evidencia actual no puede afirmarse que disminuya el drawdown sin sacrificar retorno fuera de muestra. H3 tampoco se cumplió: CQL no igualó ni superó al mejor baseline en test, aunque había parecido prometedor en validación. BC, que casi no operó, sirve como referencia de la dificultad de aprender de un dataset fijo de heurísticas que también pierden.

Funcionó la construcción de un pipeline y un simulador que hacen explícito **cuándo** se conoce cada dato y **cuándo** podría ejecutarse una orden. Esa distinción reveló que una ventaja grande en la EDA era producto de comprar a un precio atrasado. También funcionó el protocolo con comparación pareada, varias semillas, control de dependencia temporal y un modo estricto de ejecución. No funcionó la búsqueda de una mejora neta sostenida frente a abstenerse; costos, precios ya informativos y escasa actividad aprendida son explicaciones compatibles con las mediciones, sin que el experimento permita asignarles una contribución causal exacta.

Las limitaciones principales son el spread fijo en ausencia de un libro histórico completo, la aproximación `p_no = 1 − p_yes`, la cobertura parcial de trades para verificar ejecuciones, la aplicación de un mismo régimen de comisión a épocas históricas distintas y un test de solo 76 días de una única familia de mercados. El conjunto final de modelos entrenados no está incluido en el repositorio público junto con todos los datos crudos; reconstruir resultados desde cero requiere las fuentes archivadas o volver a consultarlas. El efecto mínimo de 1 % tampoco podía detectarse con suficiente potencia para CQL y BC bajo su baja actividad.

El siguiente experimento debería medir el desempeño de las políticas con medios spreads mayores y sin comisión mediante nuevas corridas declaradas como exploratorias; ampliar la evaluación a ETH horario y a otros periodos; registrar o reconstruir mejor la liquidez ejecutable; y probar datasets fuera de línea con políticas recolectoras más diversas. Estas extensiones no modifican la conclusión del test ya abierto: bajo las condiciones medidas, abstenerse fue la referencia que ningún agente logró superar.

8. Bibliografía

Las referencias se presentan con un mismo criterio: autor u organización, año cuando consta, título y enlace al original. Las figuras y cifras del experimento son elaboración propia a partir de la captura, la EDA y los reportes generados por PolyRL; no proceden de las herramientas de IA.

1. Polymarket. (2026). *Fees*. Documentación oficial. https://docs.polymarket.com/trading/fees

2. Polymarket. (2026). *Get prices history*. Referencia oficial de la API CLOB. https://docs.polymarket.com/api-reference/markets/get-prices-history
3. Binance. (2026). *Kline/Candlestick data*. Documentación oficial de la API Spot. https://developers.binance.com/en/docs/catalog/core-trading-spot-trading/api/rest-api/market
4. Ng, A. Y., Harada, D., y Russell, S. (1999). *Policy invariance under reward transformations: Theory and application to reward shaping*. ICML. https://ai.stanford.edu/~ang/papers/shaping-icml99.pdf
5. Schulman, J., Wolski, F., Dhariwal, P., Radford, A., y Klimov, O. (2017). *Proximal Policy Optimization Algorithms*. arXiv:1707.06347. https://arxiv.org/abs/1707.06347
6. Mnih, V., et al. (2015). *Human-level control through deep reinforcement learning*. Nature, 518, 529–533. https://www.nature.com/articles/nature14236
7. Kumar, A., Zhou, A., Tucker, G., y Levine, S. (2020). *Conservative Q-Learning for Offline Reinforcement Learning*. NeurIPS 33. https://proceedings.neurips.cc/paper/2020/hash/0d2b2061826a5df3221116a5085a6052-Abstract.html
8. Farama Foundation. (s. f.). *Basic Usage — Gymnasium Documentation*. https://gymnasium.farama.org/introduction/basic_usage/
9. Stable Baselines3. (2026). *PPO and DQN documentation*. https://stable-baselines3.readthedocs.io/en/master/modules/ppo.html y https://stable-baselines3.readthedocs.io/en/master/modules/dqn.html
10. d3rlpy. (2026). *Algorithms: DiscreteCQL and DiscreteBC*. https://d3rlpy.readthedocs.io/en/v2.8.1/references/algos.html
11. Pandera. (s. f.). *DataFrame Schemas*. https://pandera.readthedocs.io/en/stable/dataframe_schemas.html
12. Astral. (s. f.). *Locking and syncing — uv*. https://docs.astral.sh/uv/concepts/projects/sync/
13. GitHub. (s. f.). *GitHub Actions documentation*. https://docs.github.com/en/actions
14. Streamlit. (s. f.). *API reference*. https://docs.streamlit.io/develop/api-reference
15. Anthropic. (s. f.). *Claude Code overview*. https://code.claude.com/docs/en/overview
16. Context7. (s. f.). *Context7 MCP overview*. https://context7.com/docs/overview
17. Polymarket. (s. f.). *Positions & Tokens*. Documentación oficial. https://docs.polymarket.com/concepts/positions-tokens