

Reporte

October 6, 2026

1 Laboratorio 8

1.1 Integrantes

Nombre	Carnet	Usuario Git
Edwin Jose Gabriel De Leon Garcia	22809	EJGDLG
Gustavo Adolfo Cruz Bardales	22779	G2309
Josué Emanuel Say Garcia	22801	JosueSay
Mathew Alexander Cordero Aquino	22982	donmatthiuz

1.2 Repositorio

Branch: lab8

<https://github.com/donmatthiuz/RL/tree/lab8>

1.3 Task 1

1.3.1 Task 1.1

Antes de implementar cualquier algoritmo, el equipo de ingeniería necesita una justificación técnica sólida de las decisiones de diseño.

Inciso a Pregunta

El espacio de acción del sistema de control de palas es continuo. Argumenten formalmente por qué DQN y sus variantes de la semana anterior son inapropiados para este dominio. Su argumento debe mencionar explícitamente el operador $\arg\max$, el espacio de acción continuo, y las consecuencias computacionales de intentar aplicar DQN directamente.

Respuesta

La acción del controlador es el ángulo de paso de cada pala. Si el ángulo de cada una de las tres palas se mueve en un rango $[\beta_{\min}, \beta_{\max}]$, el espacio de acción es

$$\mathcal{A} = [\beta_{\min}, \beta_{\max}]^3 \subset \mathbb{R}^3$$

Ese conjunto tiene infinitos elementos. DQN y sus variantes (Double DQN, Dueling DQN y PER) dependen del operador $\arg\max$ en dos lugares. La política se obtiene como

$$\pi(s) = \arg \max_{a \in \mathcal{A}} Q(s, a; w)$$

y el target de cada actualización usa

$$y = r + \gamma \max_{a' \in \mathcal{A}} Q(s', a'; w^-)$$

Con cuatro acciones discretas el máximo sale de comparar cuatro salidas de la red. Con un espacio continuo la red ya no puede tener una neurona por acción y el máximo pasa a ser un problema de optimización sobre $\mathcal{A}$. Como $Q(s, \cdot; w)$ es una red neuronal, esa función tiene varios máximos locales y ningún método de búsqueda garantiza encontrar el global.

Hay dos formas de forzar DQN en este dominio y ambas fallan.

La primera es discretizar. Con k niveles por pala la capa de salida necesita k^3 neuronas. Una resolución de 0.1° en un rango de 0° a 90° da 901 niveles por pala y $901^3 \approx 7.3 \times 10^8$ salidas, una red imposible de entrenar con cualquier volumen de datos realista. Si se baja la resolución a unos pocos niveles el controlador solo puede dar saltos grandes de ángulo. Esos saltos cargan el actuador hidráulico y la estructura de la pala, y la potencia generada oscila. El error de discretización queda fijo por diseño y entrenar más no lo corrige.

La segunda es resolver el argmax de forma numérica en cada uso. Con ascenso por gradiente o con muestreo de N acciones candidatas cada decisión cuesta N evaluaciones de la red. Cada actualización cuesta $B \cdot N$ evaluaciones porque el máximo aparece en el target de cada una de las B transiciones del minibatch. Un controlador de paso decide decenas de veces por segundo, así que ese costo vuelve inviable el lazo de control. El máximo aproximado también contamina el aprendizaje. Si el optimizador se queda en un máximo local el target queda subestimado. Si se toman muchas muestras ruidosas el máximo selecciona errores positivos y la sobreestimación que estudiamos con Double DQN crece con N .

La salida es cambiar la representación de la política. En los métodos actor-crítico un actor $\mu_\theta(s)$ entrega la acción continua directamente en una sola evaluación, y el target se calcula con $Q(s', \mu_{\theta^-}(s'))$ sin ningún argmax. Esa es la estructura de DDPG, TD3 y SAC.

Inciso b Pregunta

Entre TD3 y SAC, ¿cuál recomendarían para el sistema de control de turbinas eólicas en producción? Justifiquen considerando: la naturaleza física del sistema (¿es deseable una política estocástica en un sistema de control industrial?), la eficiencia de datos durante el entrenamiento en simulación, y la robustez ante perturbaciones de viento no vistas durante el entrenamiento. Su respuesta debe argumentar ambos lados antes de tomar posición.

Respuesta

Los dos algoritmos comparten la base. Ambos son off-policy con replay buffer, usan dos críticos y toman el mínimo de ambos para frenar la sobreestimación. La diferencia está en la política. TD3 aprende una política determinista $\mu_\theta(s)$ y explora sumando ruido externo. SAC aprende una gaussiana $\pi_\theta(a | s)$ y maximiza la recompensa junto con la entropía:

$$J(\pi) = \sum_t \mathbb{E} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))]$$

A favor de TD3

Un sistema de control industrial debe responder igual ante el mismo estado. Una política estocástica en operación produce variaciones aleatorias del ángulo de paso. Cada variación mueve el actuador sin necesidad, acelera su desgaste y hace que la potencia entregada a la red oscile. TD3 produce ese comportamiento determinista de forma nativa. Un controlador determinista también es más fácil de verificar y certificar porque cada estado tiene una única acción que se puede auditar. TD3 tiene además menos piezas que ajustar. No hay temperatura α y su suavizado de la política objetivo ya da cierta tolerancia ante pequeños errores en la acción.

A favor de SAC

La estocasticidad de SAC sirve para entrenar y no tiene por qué llegar a producción. Al desplegar se usa la media de la gaussiana, $a = \tanh(\mu_\theta(s))$, y el controlador queda tan determinista como el de TD3. El argumento físico deja de ser una ventaja exclusiva de TD3.

En eficiencia de datos SAC suele aprender más rápido y con menos sensibilidad a hiperparámetros. La exploración se regula sola a través de la entropía con ajuste automático de α . En TD3 la escala del ruido de exploración se fija a mano y un mal valor deja al agente explorando de menos o golpeando los límites del actuador. Esto pesa en este dominio porque los simuladores aeroelásticos como OpenFAST son lentos y cada episodio simulado cuesta minutos.

En robustez SAC tiene el argumento más fuerte. Maximizar la entropía obliga al agente a mantener varias acciones buenas en cada estado en lugar de apostar todo a una. Eysenbach y Levine (ICLR 2022) demuestran que una política de máxima entropía es la solución de un problema robusto frente a ciertas perturbaciones de la dinámica y de la recompensa. Una ráfaga que el simulador nunca generó es justo una perturbación de la dinámica. TD3 optimiza para la distribución de viento del entrenamiento y puede quedar sobreajustado a ella. Su suavizado actúa sobre la acción y no da garantías sobre cambios en el entorno.

Posición

Recomendamos SAC para el entrenamiento en simulación y desplegar su acción media como controlador determinista. Así se obtiene la eficiencia y la robustez de SAC sin pagar el costo físico de la estocasticidad en operación. La suavidad no debe depender del algoritmo. En producción conviene limitar la tasa de cambio del ángulo de paso con un filtro o un límite de velocidad del actuador y penalizar $\|a_t - a_{t-1}\|^2$ en la recompensa. TD3 sería la opción si el regulador exigiera un controlador entrenado sin ningún componente aleatorio. La dejaríamos como alternativa de respaldo.

Inciso c Pregunta

La empresa tiene tres años de registros históricos generados por operadores humanos con distintos niveles de experiencia. Analicen si ese dataset es apropiado para aplicar CQL. Su análisis debe considerar: qué tipo de política de comportamiento β generó los datos (¿es cercana a la óptima?), qué cobertura del espacio estado-acción se puede esperar de operadores humanos, y cuál de las dos condiciones de Offline RL es más difícil de satisfacer en este dominio específico.

Respuesta

La política de comportamiento es una mezcla de las políticas de cada operador:

$$\beta(a | s) = \sum_k w_k \pi_k(a | s)$$

donde w_k es la fracción de datos que aportó el operador k . Esa mezcla está lejos de la óptima. Los operadores novatos cometen errores y tardan en reaccionar. Los expertos operan bien pero con márgenes amplios de seguridad que sacrifican potencia. Además operadores distintos responden distinto ante el mismo estado, así que β es multimodal. CQL tolera bien un β subóptimo porque está diseñado para mejorar sobre los datos sin salir de su soporte. Lo que no puede hacer es inventar buen comportamiento donde no hay registros, así que su techo queda cerca de lo que hicieron los mejores operadores.

La cobertura esperada es estrecha. Un operador humano repite los mismos procedimientos y casi nunca prueba acciones fuera de lo habitual. En un mismo estado las acciones registradas se concentran en una banda angosta y $\beta(a | s)$ vale casi cero en el resto de $\mathcal{A}$. En el espacio de estados la cobertura es buena para el viento normal porque tres años incluyen todas las estaciones. Los estados raros están poco representados. Ráfagas extremas, vientos sobre la velocidad de corte y fallas parciales de sensores aparecen pocas veces, y en esos casos el operador suele detener la turbina. Esa respuesta deja todavía menos variedad de acciones registradas.

Offline RL necesita dos condiciones. La primera es que los datos tengan suficiente calidad, es decir que β contenga comportamiento razonablemente bueno. La segunda es que cubran los pares estado-acción que visitaría la política que se quiere aprender. En este dominio la condición difícil es la cobertura. La calidad se puede manejar porque hay operadores expertos y se pueden filtrar o ponderar sus trayectorias. La cobertura no mejora con más años de registros, ya que los mismos operadores seguirán tomando las mismas decisiones. Cualquier acción mejor que la humana que nadie probó queda fuera del alcance de CQL por construcción.

El dataset sí es apropiado para CQL como punto de partida. La política resultante será parecida a la de los operadores más experimentados y algo más consistente que ellos. Para pasar de ese nivel hace falta complementar los datos con simulación o con exploración controlada en línea.

Inciso d Pregunta

Argumenten cuál es el riesgo principal de aplicar Q-Learning estándar directamente sobre el dataset histórico sin ninguna restricción de conservatividad. Usen el concepto de error de extrapolación y conéctenlo con una consecuencia operacional concreta para el sistema de turbinas.

Respuesta

Q-Learning estándar actualiza con el target

$$y = r + \gamma \max_{a'} Q(s', a'; w)$$

El máximo recorre todas las acciones posibles, incluidas las que nunca aparecen en el dataset. Para esas acciones la red no recibió ninguna señal de entrenamiento y su valor es pura extrapolación de la red. Ese es el error de extrapolación. En RL en línea el error se corrige solo, porque el agente prueba la acción sobreestimada, observa una recompensa mala y ajusta el valor. Offline esa corrección no existe porque el agente nunca interactúa con la turbina.

El operador max empeora el problema. Entre muchas acciones con errores aleatorios elige la que tiene el error positivo más grande, así que el target se infla justo con valores que no tienen respaldo en los datos. El bootstrapping propaga ese valor inflado hacia los estados anteriores y los valores Q pueden crecer sin control. La política aprendida termina eligiendo las acciones fuera de distribución porque son las que la red sobrevalora.

Un caso concreto en la turbina es la operación sobre la velocidad nominal del viento. En esa región el controlador debe aumentar el ángulo de paso para limitar la potencia y la velocidad del rotor. Los operadores siempre lo hicieron, así que el dataset casi no contiene registros de palas en ángulo bajo con viento fuerte. Q-Learning no tiene datos que digan que esa acción es peligrosa y puede extrapolar que mantener el ángulo bajo captura más energía y vale más. Al desplegar esa política el rotor se acelera por encima de su límite, las cargas sobre las palas y la torre crecen y se dispara un paro de emergencia. En el peor caso hay daño estructural en la pala o en la caja de engranajes. El riesgo principal es entonces una política que confía en acciones que nadie probó. La restricción de conservatividad de CQL ataca justo eso porque baja el valor Q de las acciones fuera del dataset y lo sube en las acciones registradas.

1.3.2 Task 1.2

El equipo quiere entender las diferencias matemáticas entre los algoritmos antes de implementarlos.

Inciso a Pregunta

Escriban el objetivo de optimización de SAC incluyendo el término de entropía. Identifiquen cada variable con su significado en el contexto del sistema de turbinas: ¿qué representa α , qué representa $\mathcal{H}(\pi(\cdot \mid S_t))$, y cómo se calibraría α automáticamente durante el entrenamiento?

Respuesta

SAC maximiza la recompensa esperada junto con la entropía de la política en cada estado visitado:

$$J(\pi) = \sum_{t=0}^T \mathbb{E}_{(S_t, A_t) \sim \rho_\pi} \left[r(S_t, A_t) + \alpha \mathcal{H}(\pi(\cdot \mid S_t)) \right]$$

con la entropía definida como

$$\mathcal{H}(\pi(\cdot \mid S_t)) = -\mathbb{E}_{a \sim \pi(\cdot \mid S_t)} [\log \pi(a \mid S_t)]$$

Variable	Significado en la turbina
S_t	Estado medido: velocidad del viento, velocidad del rotor, potencia generada, ángulo de paso actual y cargas en palas y torre
A_t	Comando de ángulo de paso para las palas
$r(S_t, A_t)$	Recompensa: seguimiento de la potencia nominal menos penalizaciones por cargas estructurales y por movimiento del actuador
ρ_π	Distribución de estados y acciones que visita la turbina bajo la política π

Variable	Significado en la turbina
$\pi(\cdot \mid S_t)$	Distribución gaussiana sobre los ángulos de paso dado el estado
$\mathcal{H}(\pi(\cdot \mid S_t))$	Qué tan dispersos son los ángulos que la política considera buenos en ese estado
α	Temperatura: cuánta recompensa está dispuesto a ceder el agente a cambio de seguir explorando

$\mathcal{H}(\pi(\cdot \mid S_t))$ mide la incertidumbre del controlador sobre qué ángulo usar. Una entropía alta significa que el agente todavía prueba varios ángulos en esa condición de viento. Una entropía baja significa que ya se decidió por un ángulo concreto. α fija el precio de esa exploración. Con α grande el agente sacrifica potencia para seguir probando ángulos distintos. Con α cercano a cero el objetivo se reduce al de RL estándar y la política se vuelve casi determinista.

Fijar α a mano es difícil porque la escala de la recompensa cambia entre regiones de operación. Por eso SAC ajusta α como un multiplicador de Lagrange que obliga a la política a mantener una entropía mínima $\bar{\mathcal{H}}$. Se minimiza

$$J(\alpha) = \mathbb{E}_{S_t \sim \mathcal{D}, a \sim \pi(\cdot \mid S_t)} \left[-\alpha (\log \pi(a \mid S_t) + \bar{\mathcal{H}}) \right]$$

La entropía objetivo suele fijarse en $\bar{\mathcal{H}} = -\dim(\mathcal{A})$, que con tres palas da -3 . El gradiente tiene una lectura directa. Si la entropía actual cae por debajo de $\bar{\mathcal{H}}$, α sube y empuja al agente a explorar más. Si está por encima, α baja y deja que la política se concentre. En la práctica se optimiza $\log \alpha$ para que α siempre sea positivo. Al inicio del entrenamiento α es alto y la turbina simulada prueba muchos ángulos. Conforme el crítico mejora α decrece y la política converge a un controlador preciso.

Inciso b Pregunta

Comparen el target de actualización del Critic en TD3 versus SAC. ¿Cuál de los dos produce estimaciones más conservadoras del valor y por qué? ¿Esa conservatividad es una ventaja o una desventaja para el dominio de turbinas?

Respuesta

El target de TD3 es

$$y_{\text{TD3}} = r + \gamma \min_{i=1,2} Q_{\phi'_i}(s', \tilde{a}'), \quad \tilde{a}' = \text{clip}(\mu_{\theta'}(s') + \text{clip}(\epsilon, -c, c), a_{\text{low}}, a_{\text{high}}), \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

El target de SAC es

$$y_{\text{SAC}} = r + \gamma \left(\min_{i=1,2} Q_{\phi'_i}(s', \tilde{a}') - \alpha \log \pi_{\theta}(\tilde{a}' \mid s') \right), \quad \tilde{a}' \sim \pi_{\theta}(\cdot \mid s')$$

Los dos toman el mínimo de dos críticos. Ese mínimo ya introduce un sesgo hacia abajo porque entre dos estimaciones ruidosas se queda con la menor. Las diferencias están en la acción siguiente y en el término de entropía.

TD3 evalúa la acción de una política determinista con un ruido pequeño y recortado. SAC evalúa una acción muestreada de la política actual y suma el término $-\alpha \log \pi_\theta(\tilde{a}' | s')$. En valor esperado ese término es $\alpha \mathcal{H}(\pi(\cdot | s'))$, un bono que premia llegar a estados donde la política todavía tiene incertidumbre. El crítico de SAC estima el valor suave, que es la recompensa futura más la entropía futura. Mientras α sea grande ese bono infla el valor por encima de la recompensa real que obtendría la turbina.

TD3 produce las estimaciones más conservadoras. Combina el mínimo de dos críticos con una política determinista sin ningún bono de exploración. Fujimoto y coautores reportan que ese diseño tiende incluso a subestimar el valor verdadero. En SAC la conservatividad del mínimo queda compensada en parte por el bono de entropía, que se desvanece conforme el ajuste automático baja α .

Para la turbina la conservatividad tiene dos caras. Del lado positivo un crítico que subestima no confía en acciones agresivas cerca de los límites del rotor. En un sistema donde un error cuesta una pala dañada es preferible equivocarse hacia la prudencia. Del lado negativo un crítico demasiado pesimista frena el aprendizaje y deja una política tímida que lleva el ángulo de paso hacia afuera antes de lo necesario. Esa política pierde energía en la región de operación nominal donde está casi toda la producción anual. La conservatividad moderada es una ventaja en este dominio y la excesiva se vuelve un costo económico directo. SAC ofrece el punto intermedio porque su bono de entropía compensa el pesimismo durante la exploración y desaparece al final, cuando la política ya es precisa.

Inciso c Pregunta

Escriban el objetivo de CQL identificando los dos términos que se añaden a la pérdida TD estándar. Expliquen en palabras qué hace cada término y por qué su combinación produce un Critic conservador. Luego argumenten qué valor de α_{CQL} recomendarían para el dataset de turbinas considerando la heterogeneidad de los operadores que lo generaron.

Respuesta

El objetivo de CQL para el crítico es

$$\min_Q \alpha_{CQL} \left(\underbrace{\mathbb{E}_{s \sim \mathcal{D}} \left[\log \sum_a \exp Q(s, a) \right]}_{\text{término 1}} - \underbrace{\mathbb{E}_{(s,a) \sim \mathcal{D}} [Q(s, a)]}_{\text{término 2}} \right) + \frac{1}{2} \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[(Q(s, a) - \hat{\mathcal{B}}^\pi \hat{Q}(s, a))^2 \right]$$

El último sumando es la pérdida TD estándar. Los dos términos nuevos van multiplicados por α_{CQL} . Con acciones continuas la suma sobre a se reemplaza por una integral que se estima con muestras de una distribución uniforme y de la política actual.

El término 1 es un máximo suave sobre todas las acciones. Minimizarlo baja el valor Q de las acciones a las que el crítico les asigna valores altos. Afecta sobre todo a las acciones que no están en el dataset, porque allí la red puede inventar valores grandes sin que ningún dato lo impida.

El término 2 entra con signo negativo. Minimizar $-Q(s, a)$ sube el valor de las acciones que sí aparecen en el dataset y compensa el empuje hacia abajo del término 1 en el soporte de los datos.

Juntos crean una brecha. Las acciones registradas por los operadores conservan su valor y las acciones que nadie probó quedan penalizadas. Kumar y coautores demuestran que con α_{CQL} suficientemente grande el valor aprendido de la política es una cota inferior del valor verdadero. La política que maximiza ese crítico prefiere quedarse dentro del soporte del dataset, que es justo la protección contra el error de extrapolación descrito en la Task 1.1d.

Para elegir α_{CQL} en las turbinas pesan dos efectos de la heterogeneidad de los operadores. El primero es que el dataset contiene acciones malas de operadores novatos. El término 2 sube el valor de todas las acciones registradas sin distinguir su calidad, así que un α_{CQL} muy alto ata la política al comportamiento promedio, errores incluidos. El segundo es que la cobertura de cada estado es angosta, como se argumentó en la Task 1.1c. Un α_{CQL} bajo deja espacio para que la política elija ángulos que ningún operador probó, que es el riesgo operacional más grave.

Como el error de extrapolación puede dañar la turbina y el apego a los datos solo cuesta eficiencia, recomendamos empezar con un valor alto. Proponemos $\alpha_{CQL} = 5$, el valor que Kumar y coautores usan en tareas de control continuo. Lo combinaríamos con la variante de Lagrange de CQL, que ajusta α_{CQL} de forma automática para mantener la brecha entre ambos términos cerca de un umbral τ . Ese ajuste evita fijar el valor a ciegas. Antes de entrenar filtraríamos o ponderaríamos las trayectorias según la experiencia del operador, así el término 2 favorece a los expertos. El valor final se validaría con evaluación off-policy sobre un año de registros reservado y luego en simulación antes de tocar una turbina real.

2 Task 2

2.1 Task 2.1

Implementen TD3 y SAC sobre el entorno Pendulum-v1 de Gymnasium como proxy del sistema de control de turbinas. Este entorno tiene espacio de acción continuo unidimensional en $[-2, 2]$ y estado tridimensional, lo que lo hace apropiado para validar las propiedades algorítmicas antes de escalar al dominio real.

Ambos algoritmos deben implementarse desde cero usando PyTorch. No se permite usar implementaciones preconstruidas de TD3 o SAC de ninguna librería de RL. Usen las siguientes especificaciones compartidas para ambos: buffer de Experience Replay con capacidad de 100,000 transiciones, minibatch de 256 transiciones, Target Networks con actualización suave $\tau = 0.005$, dos capas ocultas de 256 neuronas con activación ReLU, y entrenamiento durante 100,000 pasos de ambiente.

Para TD3 específicamente: Twin Critics, Policy Delay de 2 pasos, y Target Policy Smoothing con $\sigma = 0.2$ y clip $c = 0.5$.

Para SAC específicamente: política Gaussiana reparametrizada con tanh aplicado a la salida para restringir acciones al rango válido, Twin Critics, y α ajustado automáticamente con entropía objetivo $-\dim(A)$.

La implementación debe registrar por cada 1,000 pasos: recompensa promedio de evaluación greedy sobre 10 episodios, valor Q promedio estimado sobre un conjunto fijo de 1,000 transiciones, y entropía de la política (solo para SAC).

```
[23]: import random
      from collections import deque

      import gymnasium as gym
      import numpy as np

      import torch
      import torch.nn as nn
      import torch.nn.functional as F
      import torch.optim as optim
```

```
[24]: SEED = 42

      # Compartidos
      BUFFER_SIZE = 100_000
      BATCH_SIZE = 256
      TAU = 0.005
      TOTAL_STEPS = 100_000
      EVAL_INTERVAL = 1_000
      EVAL_EPISODES = 10
      FIXED_Q_SAMPLES = 1_000

      # TD3
      POLICY_DELAY = 2
      TARGET_NOISE = 0.2
      NOISE_CLIP = 0.5

      # Reproducibilidad
      random.seed(SEED)
      np.random.seed(SEED)
      torch.manual_seed(SEED)

      device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

      print("Device:", device)
```

Device: cpu

```
[25]: env = gym.make("Pendulum-v1")

      obs, _ = env.reset(seed=SEED)
      env.action_space.seed(SEED)

      state_dim = env.observation_space.shape[0]
      action_dim = env.action_space.shape[0]

      print("Estado inicial:", obs)
      print("Dimensión del estado:", state_dim)
```

```

print("Dimensión de la acción:", action_dim)
print("Límite inferior:", env.action_space.low)
print("Límite superior:", env.action_space.high)

```

Estado inicial: [-0.14995256 0.9886932 -0.12224312]

Dimensión del estado: 3

Dimensión de la acción: 1

Límite inferior: [-2.]

Límite superior: [2.]

```

[26]: class ReplayBuffer:
    def __init__(self, capacity=BUFFER_SIZE):
        self.buffer = deque(maxlen=capacity)

    def add(self, state, action, reward, next_state, terminated):
        self.buffer.append((
            np.asarray(state, dtype=np.float32),
            np.asarray(action, dtype=np.float32),
            np.float32(reward),
            np.asarray(next_state, dtype=np.float32),
            np.float32(terminated),
        ))

    def sample(self, batch_size=BATCH_SIZE):
        batch = random.sample(self.buffer, batch_size)
        states, actions, rewards, next_states, terminateds = zip(*batch)

        states = torch.as_tensor(
            np.asarray(states), dtype=torch.float32, device=device
        )
        actions = torch.as_tensor(
            np.asarray(actions), dtype=torch.float32, device=device
        )
        rewards = torch.as_tensor(
            np.asarray(rewards), dtype=torch.float32, device=device
        ).unsqueeze(1)
        next_states = torch.as_tensor(
            np.asarray(next_states), dtype=torch.float32, device=device
        )
        terminateds = torch.as_tensor(
            np.asarray(terminateds), dtype=torch.float32, device=device
        ).unsqueeze(1)

        return states, actions, rewards, next_states, terminateds

    def __len__(self):
        return len(self.buffer)

```

```
[27]: replay_buffer = ReplayBuffer()

state, _ = env.reset(seed=SEED)

action = env.action_space.sample()
next_state, reward, terminated, truncated, _ = env.step(action)

done = terminated or truncated

replay_buffer.add(
    state,
    action,
    reward,
    next_state,
    done
)

print("Transiciones guardadas:", len(replay_buffer))
print("Acción:", action)
print("Reward:", reward)
```

```
Transiciones guardadas: 1
Acción: [1.0958242]
Reward: -2.965626072153192
```

Se obtuvo un estado de dimensión 3 y una acción continua en $[-2, 2]$. Además, el Experience Replay almacenó correctamente una transición, estableciendo la infraestructura base para el entrenamiento posterior de **TD3** y **SAC**.

2.2 Task 2.2

Generen el dataset para el experimento de Offline RL entrenando primero una política subóptima sobre Pendulum-v1: entrenen TD3 durante solo 20,000 pasos (sin convergencia completa) y recolecten 50,000 transiciones con esa política más exploración adicional con ruido gaussiano $\mathcal{N}(0, 0.3)$. Este dataset simula los registros históricos de operadores humanos con desempeño heterogéneo.

Implementen CQL sobre ese dataset. Usen la misma arquitectura de red que en Task 2.1. La pérdida de CQL debe incluir el término TD estándar más el término de regularización con $\alpha_{CQL} \in \{0.5, 1.0, 5.0\}$. Entrenen durante 100,000 actualizaciones sobre el dataset sin ninguna interacción adicional con el entorno.

Evalúen la política aprendida por CQL ejecutándola sobre el entorno real durante 10 episodios por cada valor de α_{CQL} . Comparen esa evaluación con la recompensa promedio de la política subóptima que generó el dataset.

```
[28]: GAMMA = 0.99
      ACTOR_LR = 3e-4
      CRITIC_LR = 3e-4
```

```

SUBOPTIMAL_STEPS = 20_000
LEARNING_STARTS = 1_000
EXPLORATION_NOISE = 0.1

action_low = float(env.action_space.low[0])
action_high = float(env.action_space.high[0])
max_action = action_high

```

```

[29]: class Actor(nn.Module):
    def __init__(self, state_dim, action_dim, max_action):
        super().__init__()

        self.fc1 = nn.Linear(state_dim, 256)
        self.fc2 = nn.Linear(256, 256)
        self.fc3 = nn.Linear(256, action_dim)

        self.max_action = max_action

    def forward(self, state):
        x = F.relu(self.fc1(state))
        x = F.relu(self.fc2(x))
        return self.max_action * torch.tanh(self.fc3(x))

```

```

[30]: class Critic(nn.Module):
    def __init__(self, state_dim, action_dim):
        super().__init__()

        self.q1_fc1 = nn.Linear(state_dim + action_dim, 256)
        self.q1_fc2 = nn.Linear(256, 256)
        self.q1_fc3 = nn.Linear(256, 1)

        self.q2_fc1 = nn.Linear(state_dim + action_dim, 256)
        self.q2_fc2 = nn.Linear(256, 256)
        self.q2_fc3 = nn.Linear(256, 1)

    def forward(self, state, action):
        sa = torch.cat([state, action], dim=1)

        q1 = F.relu(self.q1_fc1(sa))
        q1 = F.relu(self.q1_fc2(q1))
        q1 = self.q1_fc3(q1)

        q2 = F.relu(self.q2_fc1(sa))
        q2 = F.relu(self.q2_fc2(q2))
        q2 = self.q2_fc3(q2)

        return q1, q2

```

```

def q1(self, state, action):
    sa = torch.cat([state, action], dim=1)

    q1 = F.relu(self.q1_fc1(sa))
    q1 = F.relu(self.q1_fc2(q1))
    return self.q1_fc3(q1)

```

```

[31]: def soft_update(source, target, tau=TAU):
    for source_param, target_param in zip(
        source.parameters(), target.parameters()
    ):
        target_param.data.copy_(
            tau * source_param.data
            + (1.0 - tau) * target_param.data
        )

```

```

[32]: class TD3:
    def __init__(self, state_dim, action_dim, max_action):
        self.max_action = max_action

        self.actor = Actor(
            state_dim, action_dim, max_action
        ).to(device)

        self.actor_target = Actor(
            state_dim, action_dim, max_action
        ).to(device)

        self.actor_target.load_state_dict(
            self.actor.state_dict()
        )

        self.actor_optimizer = optim.Adam(
            self.actor.parameters(),
            lr=ACTOR_LR
        )

        self.critic = Critic(
            state_dim, action_dim
        ).to(device)

        self.critic_target = Critic(
            state_dim, action_dim
        ).to(device)

        self.critic_target.load_state_dict(

```

```

        self.critic.state_dict()
    )

    self.critic_optimizer = optim.Adam(
        self.critic.parameters(),
        lr=CRITIC_LR
    )

    self.total_updates = 0

    def select_action(self, state):
        state = torch.as_tensor(
            state,
            dtype=torch.float32,
            device=device
        ).unsqueeze(0)

        with torch.no_grad():
            action = self.actor(state)

        return action.cpu().numpy()[0]

    def train(self, replay_buffer):
        self.total_updates += 1

        states, actions, rewards, next_states, terminateds = (
            replay_buffer.sample(BATCH_SIZE)
        )

        # Target critic
        with torch.no_grad():
            noise = (
                torch.randn_like(actions) * TARGET_NOISE
            ).clamp(-NOISE_CLIP, NOISE_CLIP)

            next_actions = (
                self.actor_target(next_states) + noise
            ).clamp(
                -self.max_action,
                self.max_action
            )

            target_q1, target_q2 = self.critic_target(
                next_states,
                next_actions
            )

```

```

        target_q = torch.min(target_q1, target_q2)

        target = (
            rewards
            + GAMMA
            * (1.0 - terminateds)
            * target_q
        )

# Twin critics
        current_q1, current_q2 = self.critic(
            states,
            actions
        )

        critic_loss = (
            F.mse_loss(current_q1, target)
            + F.mse_loss(current_q2, target)
        )

        self.critic_optimizer.zero_grad()
        critic_loss.backward()
        self.critic_optimizer.step()

# Delayed policy update
        if self.total_updates % POLICY_DELAY == 0:
            actor_actions = self.actor(states)

            actor_loss = -self.critic.q1(
                states,
                actor_actions
            ).mean()

            self.actor_optimizer.zero_grad()
            actor_loss.backward()
            self.actor_optimizer.step()

            soft_update(
                self.actor,
                self.actor_target
            )

            soft_update(
                self.critic,
                self.critic_target
            )

```

```
[33]: td3_suboptimal = TD3(
        state_dim=state_dim,
        action_dim=action_dim,
        max_action=max_action
    )

    td3_buffer = ReplayBuffer()

    print(td3_suboptimal.actor)

    Actor(
        (fc1): Linear(in_features=3, out_features=256, bias=True)
        (fc2): Linear(in_features=256, out_features=256, bias=True)
        (fc3): Linear(in_features=256, out_features=1, bias=True)
    )
```

```
[34]: state, _ = env.reset(seed=SEED)

    episode_reward = 0.0
    episode_rewards = []

    for step in range(1, SUBOPTIMAL_STEPS + 1):

        if step <= LEARNING_STARTS:
            action = env.action_space.sample()

        else:
            action = td3_suboptimal.select_action(state)

            noise = np.random.normal(
                0,
                EXPLORATION_NOISE,
                size=action_dim
            )

            action = np.clip(
                action + noise,
                action_low,
                action_high
            )

        next_state, reward, terminated, truncated, _ = (
            env.step(action)
        )

        # Guardamos únicamente terminated para el bootstrap.
        td3_buffer.add(
            state,
```

```

        action,
        reward,
        next_state,
        terminated
    )

    state = next_state
    episode_reward += reward

    if (
        step > LEARNING_STARTS
        and len(td3_buffer) >= BATCH_SIZE
    ):
        td3_suboptimal.train(td3_buffer)

    # terminated o truncated si requieren reset del entorno.
    if terminated or truncated:
        episode_rewards.append(episode_reward)
        state, _ = env.reset()
        episode_reward = 0.0

    if step % 1_000 == 0:
        recent_reward = (
            np.mean(episode_rewards[-10:])
            if episode_rewards
            else np.nan
        )

        print(
            f"Step {step:>5} | "
            f"Buffer {len(td3_buffer):>5} | "
            f"Reward reciente {recent_reward:.2f}"
        )

    print("Pasos de entrenamiento:", SUBOPTIMAL_STEPS)
    print("Transiciones almacenadas:", len(td3_buffer))
    print("Episodios completados:", len(episode_rewards))

```

```

Step 1000 | Buffer 1000 | Reward reciente -1378.91
Step 2000 | Buffer 2000 | Reward reciente -1369.28
Step 3000 | Buffer 3000 | Reward reciente -1419.59
Step 4000 | Buffer 4000 | Reward reciente -1401.39
Step 5000 | Buffer 5000 | Reward reciente -1162.84
Step 6000 | Buffer 6000 | Reward reciente -900.43
Step 7000 | Buffer 7000 | Reward reciente -717.94
Step 8000 | Buffer 8000 | Reward reciente -499.92
Step 9000 | Buffer 9000 | Reward reciente -281.58
Step 10000 | Buffer 10000 | Reward reciente -190.03

```

```

Step 11000 | Buffer 11000 | Reward reciente -176.15
Step 12000 | Buffer 12000 | Reward reciente -137.11
Step 13000 | Buffer 13000 | Reward reciente -146.92
Step 14000 | Buffer 14000 | Reward reciente -156.81
Step 15000 | Buffer 15000 | Reward reciente -244.17
Step 16000 | Buffer 16000 | Reward reciente -398.44
Step 17000 | Buffer 17000 | Reward reciente -276.81
Step 18000 | Buffer 18000 | Reward reciente -122.56
Step 19000 | Buffer 19000 | Reward reciente -120.80
Step 20000 | Buffer 20000 | Reward reciente -163.66
Pasos de entrenamiento: 20000
Transiciones almacenadas: 20000
Episodios completados: 100

```

2.3 Task 2.3

Con base en los resultados de ambos experimentos, respondan:

- Grafiquen las curvas de aprendizaje de TD3 y SAC en la misma figura con media móvil de 10 evaluaciones. ¿Cuál converge más rápido? ¿Cuál alcanza mayor recompensa final? ¿El resultado coincide con la predicción teórica de la Task 1.1b? Si hay discrepancia, argumenten la causa.
- Grafiquen el valor Q promedio durante el entrenamiento para TD3 y SAC. ¿Observan diferencias en la magnitud de los valores estimados? Conéctenlo con el análisis de conservatismo de la Task 1.2b.
- Para el experimento de CQL: ¿alguno de los tres valores de α_{CQL} produce una política que supera a la política subóptima que generó el dataset? ¿Cuál valor de α_{CQL} funciona mejor y por qué? Si ningún valor supera al dataset, argumenten a qué atribuyen ese resultado considerando las características del dataset que generaron.
- Conexión entre paradigmas: con base en los resultados de ambos experimentos, argumenten cuándo recomendarían usar TD3 o SAC versus CQL para el sistema de turbinas eólicas real. Consideren explícitamente: disponibilidad de un simulador confiable, costo de interacción con el sistema real, calidad del dataset histórico disponible, y urgencia de despliegue. Esta pregunta no puede responderse correctamente sin los resultados específicos de sus experimentos.
- Investigación bibliográfica: busquen y lean un paper publicado entre 2023 y 2025 que aplique Offline RL (CQL, BCQ, IQL, o variantes) a un problema de control de sistemas energéticos, robótica industrial, o infraestructura física. El paper debe ser de NeurIPS, ICML, ICLR, IEEE Transactions on Power Systems, o similar. Escriban un resumen técnico de media página con: el problema que resuelve, qué algoritmo de Offline RL usa y por qué, los resultados principales, y una reflexión sobre si las limitaciones del dataset que identificaron en la Task 1.1c también aparecen en ese trabajo y cómo las manejan.

2.4 Prompts

Siguiendo la nota del laboratorio, el contenido técnico se trabajó con fuentes de internet. La IA generativa se usó solo en dos tareas de soporte para el reporte. Los prompts fueron los siguientes.

2.4.1 Prompt 1: generar el Reporte.pdf

Uso: generar el Reporte.pdf. Aplica a todo el reporte.

Genera el Reporte.pdf usando mi nix-shell -p porque tengo NixOS.

Por qué funcionó: en NixOS no se pueden instalar paquetes con pip de forma global y las librerías del sistema no están en las rutas comunes. Al decir de entrada que el sistema es NixOS y que se use nix-shell -p, la respuesta armó un entorno temporal con nbconvert, pandoc y texlive en un solo comando. Así se generó el PDF sin instalar nada de forma permanente y sin errores de dependencias de LaTeX.

2.4.2 Prompt 2: corregir las fórmulas en markdown

Uso: fórmulas de la Task 1.1 y la Task 1.2.

Prompt:

Corrige las fórmulas del markdown del notebook. No están escritas como en el documento de la tarea. Usa la misma notación que el documento, por ejemplo $\pi(\cdot | S_t)$, $\mathcal{H}$ y α_{CQL} , y escríbelas en LaTeX para que se rendericen bien en el PDF.

Por qué funcionó: el prompt indica el problema concreto, que la notación no coincidía con la del documento, y da ejemplos de los símbolos esperados. Con esos ejemplos la corrección se limitó a la notación sin cambiar el contenido de las respuestas. Pedir LaTeX explícitamente asegura que las fórmulas se vean igual en el notebook y en el PDF generado con nbconvert.