

Hoja de Trabajo 2

Integrantes

Nombre	Carnet	Usuario Git
Edwin Jose Gabriel De Leon Garcia	22809	EJGDLG
Gustavo Adolfo Cruz Bardales	22779	G2309
Josué Emanuel Say Garcia	22801	JosueSay
Mathew Alexander Cordero Aquino	22982	donmatthiuz

Repositorio

[Link al Repositorio](#)

Task 1

Responda las siguientes preguntas de forma clara, concisa y argumentada. No basta con definir, se espera que usted conecte el concepto con sus implicaciones prácticas o estratégicas.

Inciso 1

Elijan un sistema real que pueda modelarse como un k-armed bandit. Su modelado debe incluir:

Sistema elegido: selección de la miniatura de portada que se muestra para una serie en una plataforma de streaming, con el fin de maximizar los clics de los usuarios.

El sistema recibe un catálogo de portadas producidas para una misma serie y debe decidir cuál desplegar. Cada vez que un usuario ve la portada, el sistema observa si genera clic o no, y con esa señal ajusta su preferencia por una u otra imagen. El reto es equilibrar entre repetir la portada que hasta ahora convierte mejor y probar otras para descubrir si alguna convierte aún más.

Inciso a

Definición formal de los **k** brazos: qué representa cada acción y por qué el conjunto de acciones es finito y discreto en este dominio.

Respuesta:

En este sistema cada brazo representa una de las miniaturas de portada disponibles para la serie. El conjunto de acciones es

$$\mathcal{A} = a_1, a_2, \dots, a_k$$

donde cada acción a_i significa "mostrar la miniatura i como portada de la serie". El número de brazos k corresponde a la cantidad de portadas creadas para esa serie. Elegir un brazo $A_t = a_i$ es la decisión de qué imagen desplegar, y a cada brazo le corresponde un valor real desconocido $q_*(a_i) = \mathbb{E}[R_t \mid A_t = a_i]$, la tasa de clic esperada de esa portada, que el agente no conoce y solo puede estimar mediante $Q_t(a_i)$.

El conjunto de acciones es finito porque las miniaturas son un catálogo fijo creado de antemano por el equipo de diseño y no se generan portadas nuevas durante la operación.

El conjunto es discreto porque las acciones son mutuamente excluyentes y sin puntos intermedios, se muestra la portada a_2 o la a_5 , pero no existe una "portada 2.5" ni una mezcla continua entre dos miniaturas. Cada brazo es una categoría separada e identificable, sin una noción de cercanía entre ellas, lo cual encaja con el supuesto del k -armed bandit de un espacio de acciones enumerable donde cada acción se estima por separado.

Al ser k pequeño, la exploración aleatoria del epsilon-greedy sigue siendo viable, y permite mantener una estimación $Q_t(a_i)$ por brazo actualizada de forma independiente mediante $Q_{n+1} = Q_n + \alpha(R_n - Q_n)$.

Inciso b

Diseño justificado de la función de recompensa: qué se mide, cómo se mide, y qué supuestos distribucionales son razonables para ese dominio. Si la recompensa no es gaussiana, argúmentenlo.

Respuesta:

Qué se mide. La recompensa mide la interacción del usuario con la portada mostrada, que es la señal directamente ligada al objetivo del sistema: maximizar los clics:

$$R_t = \begin{cases} 1 & \text{si el usuario hace clic en la portada mostrada} \\ 0 & \text{en caso contrario} \end{cases}$$

Se elige el clic porque es la señal más inmediata, atribuible sin ambigüedad a la miniatura elegida en ese instante.

Cada vez que se muestra la portada a_i a un usuario (una impresión) se registra un único valor $R_t \in 0, 1$. El valor verdadero del brazo, $q_*(a_i) = \mathbb{E}[R_t \mid A_t = a_i]$, es entonces la tasa de clic (CTR) esperada de esa miniatura "la probabilidad de que una impresión de a_i termine en clic". El agente lo estima con el promedio de las recompensas observadas:

$$Q_t(a_i) = \frac{\text{clics de } a_i}{\text{impresiones de } a_i}$$


Esta estimación se puede mantener de forma incremental con

$Q_{n+1} = Q_n + \alpha(R_n - Q_n)$, sin guardar el historial completo, lo cual es indispensable en un sistema con millones de impresiones.

Supuesto distribucional: la recompensa NO es gaussiana. Como R_t solo puede valer 0 o 1, no puede modelarse con una distribución normal, que es continua y con soporte en toda la recta real.

- Soporte discreto y acotado. La observación vive en 0, 1.
- Asimetría en CTR bajos. Las tasas de clic reales suelen ser pequeñas (del orden de unos pocos por ciento), lo que produce una distribución muy sesgada hacia el 0; la simetría de la gaussiana no captura ese comportamiento.

Tres pasos del bandido:



Inciso c

Análisis de estacionariedad: ¿los valores verdaderos ($q_*(a)$) cambian con el tiempo en este sistema? ¿En qué escala temporal? ¿Qué implicaciones tiene eso para el algoritmo de actualización?

Respuesta:

¿Cambian los $q_*(a)$ con el tiempo?

Sí. En este sistema el valor verdadero de cada brazo "la tasa de clic esperada $q_*(a_i)$ de la miniatura i " no es constante, por lo que el sistema es no estacionario. La atracción de una portada depende de factores que evolucionan: las tendencias culturales, la novedad de la

serie, la composición de la audiencia que llega a esa pantalla y hasta la estación del año. Una miniatura que hoy convierte al 8 % puede caer al 3 % meses después sin que la imagen haya cambiado, simplemente porque el contexto que la hacía atractiva se movió. Esto rompe el supuesto estacionario que asume que "el valor de una acción se mantiene igual durante todo el periodo".

¿En qué escala temporal cambian? Hay que distinguir varias escalas, porque cada una exige una respuesta distinta:

- Corto plazo (horas / días): oscilaciones por hora del día o día de la semana (no es igual la audiencia de un lunes en la mañana que la de un viernes en la noche). Es una variación de alta frecuencia pero de amplitud moderada.
- Mediano plazo (semanas / meses): desgaste por novedad. Una portada recién estrenada capta la atención por ser nueva; conforme los usuarios la ven repetidamente, su CTR decae. Es la escala más relevante para el diseño del algoritmo.
- Largo plazo (temporadas / años): cambios en tendencias, en el catálogo competidor o en la base de usuarios, que pueden redefinir por completo cuál portada es la mejor.

Implicaciones para el algoritmo de actualización. El promedio muestral es inadecuado aquí. Como da el mismo peso a toda observación histórica, una impresión de hace un año pesa igual que la de hoy, lo que hace que el agente reaccione con lentitud o directamente no reaccione cuando el mejor brazo cambia. La consecuencia es que quedaría anclado a una portada que fue óptima en el pasado pero ya no lo es.

La solución que corresponde a este dominio es usar un paso constante $\alpha \in (0, 1]$ en lugar de $\alpha = 1/n$:

$$Q_{n+1} = Q_n + \alpha(R_n - Q_n)$$

Con α constante, la estimación se convierte en un promedio de recencia ponderada exponencialmente:

$$Q_{n+1} = (1 - \alpha)^n Q_0 + \sum_{i=1}^n \alpha(1 - \alpha)^{n-i} R_i$$

donde las impresiones recientes pesan más y las antiguas decaen exponencialmente. Esto le da al agente una "memoria corta" que le permite seguir el CTR real conforme se mueve.

La elección de α implica un compromiso ligado a la escala temporal:

- Un α grande (memoria corta) rastrea cambios rápidos pero introduce más varianza, porque reacciona en exceso al ruido de cada impresión.
- Un α pequeño (memoria larga) estima con más estabilidad pero se rezaga ante cambios reales.

Para este sistema, α debe calibrarse a la escala de mediano plazo —el desgaste por novedad de semanas/meses—, que es la dinámica dominante y accionable, absorbiendo el ruido de corto plazo con suficientes impresiones sin quedar rezagado ante las tendencias de largo plazo.

La no estacionariedad tiene una segunda implicación: dado que el mejor brazo puede cambiar, el agente nunca puede dejar de explorar del todo. Un epsilon-greedy con ϵ decayendo a cero, o un greedy puro, se congelaría en la portada antes óptima.

Inciso d

Identificación de restricciones de exploración: ¿hay costos económicos, de seguridad o regulatorios que limiten cuánto puede explorar el sistema?

Respuesta:

Cada impresión gastada en una miniatura peor tiene un costo real. Ese costo se cuantifica con el regret acumulado $L_T = \sum_a \Delta_a N_T(a)$: cada vez que se muestra una portada subóptima se suma un gap $\Delta_a = q_*(a) - q(a)$ de clics perdidos.

Costos económicos. Son los más directos. Cada impresión asignada a una portada inferior significa clics y por tanto reproducciones, retención y en última instancia ingresos por suscripción o publicidad que no ocurrieron. En un sistema con millones de impresiones diarias, incluso una fracción pequeña de exploración excesiva se traduce en una pérdida agregada considerable. Esto acota ϵ a valores bajos ($[0.01, 0.1]$) y hace preferible una exploración dirigida como UCB, que no malgasta impresiones en brazos ya bien estimados, sobre la exploración uniforme del epsilon-greedy que puede volver a probar una portada visitada cien veces.

Costos de experiencia de usuario. Explorar demasiado degrada la percepción del producto. Mostrar repetidamente portadas poco atractivas o inconsistentes hace que la interfaz se sienta errática, y a diferencia del regret de clics, este daño puede afectar la retención a largo plazo del usuario, un costo que el modelo de bandido puro ni siquiera captura porque no tiene estados.

La exploración debe ser acotada mediante un ϵ bajo o un c moderado en UCB; dirigida hacia los brazos genuinamente inciertos para minimizar el regret; y segura porque el catálogo de brazos ya está filtrado antes de que el algoritmo actúe. El objetivo es que aprenda rápido cuál portada conviene y deje de pagar el costo de explorar más de lo necesario.

Inciso 2

Con base en el análisis anterior, propongan y justifiquen:

Inciso a

La estrategia de selección de acción más apropiada para su dominio, con el valor concreto del hiperparámetro relevante (ϵ o c) y la justificación de ese valor.

Respuesta:

La estrategia recomendada para este sistema es Upper Confidence Bound, con constante de exploración $c = 1$. Esto, ya que como se explicaba en el inciso 1.d, la restricción

económica exige minimizar el regret por impresión, y la exploración uniforme del epsilon-greedy desperdicia impresiones al volver a probar portadas ya bien estimadas con la misma probabilidad que a las inciertas. Pero UCB, dirige la exploración solo hacia los brazos con más incertidumbre, mediante la regla:

$$A_t = \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

El término $\sqrt{\ln t / N_t(a)}$ funciona como un bono de incertidumbre que decrece conforme una portada acumula impresiones $N_t(a)$ las miniaturas que ya están bien medidas dejan de explorarse y el algoritmo gasta la exploración solo en las que todavía son inciertas.

Luego, elegimos $c = 1$ porque un c más alto (por ejemplo 2) infla demasiado el bono y termina reexplorando portadas ya medidas y uno más bajo (por ejemplo 0.5) explora menos de lo necesario para seguir el desgaste por novedad. Con $c = 1$ quedamos en el medio, y de ahí lo ajustaremos empíricamente en el análisis de sensibilidad.

Descartamos greedy puro y epsilon-greedy con ε decayendo a cero por lo mismo de que si el algoritmo deja de explorar, se queda pegado a la portada que era óptima antes cuando el CTR cambie. Un epsilon-greedy con ε fijo bajo (~ 0.05) sí sería una alternativa viable, pero UCB con $c = 1$ le gana en regret esperado bajo estas condiciones

Inciso b

La regla de actualización de estimaciones (paso variable o constante) con justificación ligada al análisis de estacionariedad.

Respuesta:

La regla de actualización es la incremental con paso constante $\alpha = 0.05$:

$$Q_{n+1}(a) = Q_n(a) + \alpha [R_n - Q_n(a)]$$

La justificación se apoya directamente en el análisis de estacionariedad del inciso 1.c. Se descartó el promedio muestral ($\alpha = 1/n$) porque asigna el mismo peso a toda observación histórica, y en un sistema donde el CTR se desgasta por novedad en escala de semanas a meses eso implica que una impresión de hace un año pesaría igual que la de hoy.

Si dejamos el valor de α fijo, la fórmula se convierte en un promedio donde los datos más recientes tienen más peso:

$$Q_{n+1} = (1 - \alpha)^n Q_0 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i$$

lo cual le da al agente la "memoria corta" necesaria para seguir el CTR real conforme se mueve.

El valor $\alpha = 0.05$ se elige para calibrar al agente contra la escala de mediano plazo (semanas/meses) identificada anteriormente como la dinámica dominante. Con ese paso,

el tiempo característico de decaimiento del peso de una observación es del orden de $1/\alpha = 20$ impresiones suficiente para absorber el ruido de una recompensa Bernoulli individual pero lo bastante ágil para reflejar un cambio real en el CTR de un brazo. Un α mayor reaccionaría demasiado al ruido de cada impresión y uno menor reaccionaría con lentitud ante el desgaste por novedad.

Inciso c

Un ejemplo numérico con al menos seis observaciones que ilustre cómo evoluciona ($Q_t(a)$) para dos acciones distintas bajo la regla elegida, mostrando cómo la estimación converge o se adapta.

Respuesta:

Simulamos seis impresiones para dos portadas (a_1 y a_2) usando $\alpha = 0.05$ y una estimación inicial $Q_0 = 0.05$. Las respuestas de los usuarios fueron:

- a_1 : $\{1, 0, 0, 1, 0, 0\}$ (2 clics de 6 impresiones $\rightarrow$ 33% CTR)
- a_2 : $\{1, 1, 1, 1, 0, 1\}$ (5 clics de 6 impresiones $\rightarrow$ 83% CTR)

Calculando paso a paso con la fórmula $Q_{n+1} = Q_n + \alpha(R_n - Q_n)$:

t	R_t (a_1)	$Q_t(a_1)$	R_t (a_2)	$Q_t(a_2)$
0	—	0.05000	—	0.05000
1	1	0.09750	1	0.09750
2	0	0.09262	1	0.14263
3	0	0.08799	1	0.18549
4	1	0.13359	1	0.22622
5	0	0.12691	0	0.21491
6	0	0.12057	1	0.25416

De lo que podemos concluir que:

- Aunque ambas empiezan igual, tras solo seis pasos la estimación de a_2 (0.254) ya duplica a la de a_1 (0.121), adaptándose bien a la diferencia de clics reales.
- En $t = 5$, el único fallo de a_2 apenas baja su estimación (0.226 $\rightarrow$ 0.215). Esto es gracias a que el $\alpha = 0.05$ evita que un solo evento aislado (un "no clic") arruine todo el historial.
- Seis pasos no bastan para "congelar" un valor definitivo (y con un α constante el algoritmo nunca lo hace). Esto es ideal para entornos dinámicos: el agente no se queda estancado y, si las preferencias de los usuarios cambian mañana, se adaptará al nuevo CTR sin problemas.

Task 2

Realice y responda:

Inciso 1

Implementen en Python un simulador de k-armed bandit con las tres estrategias vistas en clase: greedy puro, epsilon-greedy y UCB1. Su implementación debe incluir:

Inciso a

Una clase `KArmedBandit` con soporte para modo estacionario y no estacionario. En modo no estacionario, los valores ($q_*(a)$) deben perturbarse cada cierto número de pasos configurable.

Inciso b

Una clase por cada estrategia con métodos `select_action` y `update`, implementando la regla incremental con soporte para paso variable y paso constante.

Inciso c

Un loop de experimento que corra al menos **500 episodios independientes de 1000 pasos**, calculando recompensa promedio por paso y **regret** acumulado.

Inciso d

Cuatro gráficas: recompensa promedio y regret acumulado en el entorno estacionario, y las mismas dos métricas en el entorno no estacionario.

Resultado

```
In [1]: from task2_inciso1.KArmedBandit import *

estrategias = {
    "Greedy": lambda k: EstrategiaGreedy(k),
    "Epsilon-Greedy (0.1)": lambda k: EstrategiaEpsilonGreedy(k, epsilon=0.1),
    "UCB1 (c=2)": lambda k: EstrategiaUCB1(k, c=2),
}


simulador_estacionario = SimuladorBandit(
    k=10,
    num_pasos=1000,
    num_episodios=500,
    estacionario=True,
)
recompensa_est, regret_est = simulador_estacionario.ejecutar(estrategias)
simulador_estacionario.graficar(recompensa_est, regret_est, "Entorno estacionario")

simulador_no_estacionario = SimuladorBandit(
    k=10,
    num_pasos=1000,
    num_episodios=500,
    estacionario=False,
```

```

    intervalo_perturbacion=100,
    sigma_perturbacion=0.01,
)
recompensa_no_est, regret_no_est = simulador_no_estacionario.ejecutar(estراتيجias)
simulador_no_estacionario.graficar(recompensa_no_est, regret_no_est, "Entorno no estacionario")

```



Inciso 2

Con base en los resultados de la implementación:

Inciso a

Analicen el comportamiento del regret acumulado de cada estrategia en el entorno estacionario. ¿La jerarquía entre estrategias coincide con lo esperado teóricamente? ¿A partir de qué paso el regret de UCB comienza a diferenciarse del de epsilon-greedy?

Respuesta:

En el entorno estacionario la jerarquía final fue **UCB1 ($c = 2$) < epsilon-greedy ($\epsilon = 0.1$) < greedy** en regret acumulado. Al paso 1000, los regrets promedio fueron 146.88, 227.13 y 487.94, respectivamente. Por tanto, la jerarquía sí coincide con lo esperado teóricamente: greedy puede quedar atrapado en una acción que pareció buena por ruido inicial; epsilon-greedy continúa seleccionando acciones al azar con probabilidad fija y su regret crece casi linealmente; UCB concentra la exploración en acciones inciertas y reduce progresivamente su costo marginal.

Al inicio UCB paga el costo de probar los diez brazos: en el paso 100 su regret (58.08) todavía era mayor que el de epsilon-greedy (50.46), y en el paso 200 ambos seguían cercanos (81.27 frente a 78.25). Las curvas se cruzan después del paso 200; usando como

criterio una ventaja de al menos 5 unidades de regret sostenida durante 25 pasos, la separación clara comienza aproximadamente en el **paso 297**. Desde allí la diferencia aumenta: en el paso 500 UCB registra 116.42 frente a 139.94 de epsilon-greedy, y termina con una ventaja de 80.26 unidades.

Inciso b

Analicen qué ocurre en el entorno no estacionario. ¿Qué estrategia se adapta mejor? ¿Cómo cambia el resultado al usar paso constante versus paso variable?


Respuesta:

En el entorno no estacionario las diferencias fueron menores porque los valores comenzaron en cero y la perturbación usada fue suave ($\sigma = 0.01$ cada 100 pasos). Con paso variable, epsilon-greedy obtuvo el menor regret final (27.77), seguido de UCB (28.40) y greedy (28.50). Epsilon-greedy se adapta mejor porque mantiene exploración permanente y puede volver a descubrir un brazo cuyo valor mejoró; greedy depende de que el ruido lo lleve a reconsiderar acciones, mientras que el bono de UCB disminuye al crecer sus conteos y no olvida por sí mismo la información antigua.

El paso constante $\alpha = 0.05$ mejoró a epsilon-greedy de 27.77 a **26.43** y a greedy de 28.50 a 26.88, porque da mayor peso a recompensas recientes. En cambio, UCB pasó de 28.40 a 28.85: actualizar Q con paso constante no reinicia sus conteos, así que el bono de exploración sigue reduciéndose y UCB1 conserva una limitación estructural ante cambios. En este experimento, por tanto, la mejor combinación fue **epsilon-greedy con paso constante**. La ventaja es moderada, coherente con una no estacionariedad débil; con cambios más frecuentes o grandes se esperaría una diferencia más visible a favor del paso constante.

```
In [1]: from IPython.display import Image, display
from task2_inciso1.analisis_inciso2 import main as ejecutar_sensibilidad

resultados_sensibilidad = ejecutar_sensibilidad(mostrar_json=False)
display(Image(filename="sensibilidad_hiperparametros.png"))
```




Inciso c

Realicen un análisis de sensibilidad: corran epsilon-greedy con al menos tres valores distintos de ϵ y UCB con al menos tres valores de c . Grafiquen el regret final en función del hiperparámetro y discutan cuál rango de valores es más robusto.

Respuesta:

Se evaluaron $\epsilon \in \{0.01, 0.03, 0.05, 0.10, 0.20, 0.30\}$ y $c \in \{0.25, 0.5, 1, 2, 4\}$, con 500 episodios independientes de 1000 pasos por configuración. La figura muestra el regret acumulado final promedio; las corridas estacionarias usaron paso variable y las no estacionarias, $\alpha = 0.05$.



Estrategia	Hiperparámetro	Regret final estacionario	Regret final no estacionario
epsilon-greedy	0.01	349.84	25.97
epsilon-greedy	0.03	253.57	26.43
epsilon-greedy	0.05	209.69	27.18
epsilon-greedy	0.10	236.30	26.76
epsilon-greedy	0.20	349.94	27.98
epsilon-greedy	0.30	492.49	27.56
UCB1	0.25	97.68	27.41
UCB1	0.50	53.18	27.34
UCB1	1.00	57.47	27.37
UCB1	2.00	148.46	28.48
UCB1	4.00	373.23	29.18

En el entorno estacionario, epsilon-greedy es más robusto aproximadamente entre $\epsilon = 0.03$ y 0.10 , con mínimo en 0.05 ; valores muy bajos aprenden lentamente y valores altos pagan exploración aleatoria excesiva. Para UCB, el rango robusto es $c = 0.5$ a 1 ,

cuyos regrets (53.18 y 57.47) son muy cercanos; $c \geq 2$ sobreexplora. En el entorno no estacionario las curvas son más planas: epsilon entre 0.01 y 0.10 y UCB entre 0.25 y 1 son estables. No conviene interpretar una diferencia pequeña como un óptimo universal, sino elegir dentro de esas mesetas robustas.

Inciso d

Cierren con una sección de diseño aplicado: tomando los resultados anteriores, ¿qué configuración específica recomendarían para el sistema real que modelaron en la entrega parcial? Justifiquen la recomendación con evidencia de sus experimentos, no solo con argumentos teóricos.

Respuesta:

Para el sistema real de selección de miniaturas recomendamos **epsilon-greedy con $\varepsilon = 0.05$ y actualización de paso constante $\alpha = 0.05$** . Esta configuración mantiene un 5 % de exploración para detectar cambios en las preferencias y hace que las estimaciones olviden gradualmente clics antiguos, lo cual corresponde al desgaste por novedad y a los cambios de audiencia descritos en la entrega parcial.

La recomendación se apoya en los experimentos: (1) entre los epsilon evaluados, 0.05 produjo el menor regret estacionario, 209.69; (2) el intervalo 0.03–0.10 fue la zona estable, por lo que 0.05 no es un extremo frágil; (3) en el experimento no estacionario comparativo, epsilon-greedy con paso constante redujo el regret de 27.77 a 26.43 y superó a UCB $c = 2$ con paso constante, que obtuvo 28.85. Aunque $\varepsilon = 0.01$ dio el menor valor en una corrida de sensibilidad no estacionaria, las diferencias entre 0.01 y 0.10 fueron pequeñas y 0.05 ofrece un compromiso más seguro ante cambios futuros de mayor magnitud.

Esto modifica la recomendación teórica inicial de UCB: UCB fue claramente superior en el entorno estacionario cuando c estuvo entre 0.5 y 1, pero el sistema real es no estacionario y UCB1 reduce su bono según conteos históricos que nunca se reinician. Si se quisiera conservar UCB, sería necesario agregar una ventana deslizante, descuento de conteos o reinicios periódicos; esa variante no fue parte de la implementación evaluada. En producción se iniciaría con $\varepsilon = 0.05$, $\alpha = 0.05$, únicamente con miniaturas aprobadas, y se monitorearía CTR y regret para recalibrar si cambia la velocidad de deriva.